Séries Temporelles Multivariées

Chapitre 4

Économétrie des séries temporelles

Structure du cours :

Autorégressions Vectorielles – VAR

Exemples de base

Propriétés

- Stationnarité

Revisiter les processus ARMA univariés

Prévision

- Causalité de Granger
- Fonctions de réponse impulsionnelle

Cointégration

- Examiner les relations à long terme
- Déterminer si un VAR est cointégré
- Modèles de Correction d'Erreur
- Tests de Cointégration - Engle-Granger

Autorégressions Vectorielles – VAR

Pourquoi l'analyse VAR ?

VAR Stationnaires

- Déterminer si les variables se rétroagissent les unes sur les autres
- Améliorer les prévisions
- Modéliser l'effet d'un choc dans une série sur une autre
- Différencier entre les dynamiques à court terme et à long terme

Cointégration

- Lier les marches aléatoires
- Découvrir les relations à long terme
- Peut améliorer considérablement les prévisions à moyen et long terme

Définition du VAR

Autorégression d'ordre P, AR(P) :

$$y_t = \phi_0 + \phi_1 y_{t-1} + \ldots + \phi_P y_{t-p} + \varepsilon_t$$

Autorégression vectorielle d'ordre P, VAR(P) :

$$\mathbf{y}_t = \mathbf{\Phi}_0 + \mathbf{\Phi}_1 \mathbf{y}_{t-1} + \ldots + \mathbf{\Phi}_P \mathbf{y}_{t-p} + \varepsilon_t$$

où $\mathbf{y}_t$ et ε_t sont des vecteurs de dimension $k \times 1$

VAR(1) bivarié :

$$\begin{pmatrix} y_{1,t} \\ y_{2,t} \end{pmatrix} = \begin{pmatrix} \phi_{01} \\ \phi_{02} \end{pmatrix} + \begin{pmatrix} \phi_{11} & \phi_{12} \\ \phi_{21} & \phi_{22} \end{pmatrix} \begin{pmatrix} y_{1,t-1} \\ y_{2,t-1} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1,t} \\ \varepsilon_{2,t} \end{pmatrix}$$

Exprime de manière compacte deux modèles liés :

$$y_{1,t} = \phi_{01} + \phi_{11} y_{1,t-1} + \phi_{12} y_{2,t-1} + \varepsilon_{1,t}$$

$$y_{2,t} = \phi_{02} + \phi_{21} y_{1,t-1} + \phi_{22} y_{2,t-1} + \varepsilon_{2,t}$$

Stationnarité Revisitée

La stationnarité est une forme statistiquement significative de régularité.

Un processus stochastique y_t est stationnaire en covariance si :

- $E[y_t] = \mu, \quad \forall t$
- $V[y_t] = \sigma^2, \quad \sigma^2 < \infty, \forall t$
- $E[(y_t - \mu)(y_{t-s} - \mu)] = \gamma_s, \quad \forall t, s$

Stationnarité de l'AR(1) : $y_t = \phi y_{t-1} + \varepsilon_t$

- $\mid \phi \mid < 1$
- ε_t est un bruit blanc

Stationnarité de l'AR(P) : $y_t = \phi_1 y_{t-1} + \ldots + \phi_P y_{t-P} + \varepsilon_t$

- Les racines de $(z^P - \phi_1 z^{P-1} - \phi_2 z^{P-2} - \ldots - \phi_{P-1} z - \phi_P)$ sont inférieures à 1
- ε_t est un bruit blanc

Pas de dépendance à t

Relation avec AR

AR(1)

$$
\begin{aligned}
y_t &= \phi_0 + \phi_1 y_{t-1} + \varepsilon_t \\
&= \phi_0 + \phi_1(\phi_0 + \phi_1 y_{t-2} + \varepsilon_{t-1}) + \varepsilon_t \\
&= \phi_0 + \phi_1\phi_0 + \phi_1^2 y_{t-2} + \phi_1\varepsilon_{t-1} + \varepsilon_t \\
&= \phi_0 + \phi_1\phi_0 + \phi_1^2(\phi_0 + \phi_1 y_{t-3} + \varepsilon_{t-2}) + \phi_1\varepsilon_{t-1} + \varepsilon_t \\
&\vdots \\
&= \sum_{i=0}^{\infty} \phi_1^i \phi_0 + \sum_{i=0}^{\infty} \phi_1^i \varepsilon_{t-i} \\
&= (1-\phi_1)^{-1}\phi_0 + \sum_{i=0}^{\infty} \phi_1^i \varepsilon_{t-i}
\end{aligned}
$$

Relation avec AR

VAR(1)

$$
\begin{aligned}
\mathbf{y}_t &= \mathbf{\Phi}_0 + \mathbf{\Phi}_1 \mathbf{y}_{t-1} + \varepsilon_t \\
&= \mathbf{\Phi}_0 + \mathbf{\Phi}_1 (\mathbf{\Phi}_0 + \mathbf{\Phi}_1 \mathbf{y}_{t-2} + \varepsilon_{t-1}) + \varepsilon_t \\
&= \mathbf{\Phi}_0 + \mathbf{\Phi}_1 \mathbf{\Phi}_0 + \mathbf{\Phi}_1^2 \mathbf{y}_{t-2} + \mathbf{\Phi}_1 \varepsilon_{t-1} + \varepsilon_t \\
&= \mathbf{\Phi}_0 + \mathbf{\Phi}_1 \mathbf{\Phi}_0 + \mathbf{\Phi}_1^2 (\mathbf{\Phi}_0 + \mathbf{\Phi}_1 \mathbf{y}_{t-3} + \varepsilon_{t-2}) + \mathbf{\Phi}_1 \varepsilon_{t-1} + \varepsilon_t \\
&\vdots \\
&= \sum_{i=0}^{\infty} \mathbf{\Phi}_1^i \mathbf{\Phi}_0 + \sum_{i=0}^{\infty} \mathbf{\Phi}_1^i \varepsilon_{t-i} \\
&= (\mathbf{I}_k - \mathbf{\Phi}_1)^{-1} \mathbf{\Phi}_0 + \sum_{i=0}^{\infty} \mathbf{\Phi}_1^i \varepsilon_{t-i}
\end{aligned}
$$

Propriétés d'un VAR(1) et AR(1)

Moyenne, Variance, Autocovariance

Propriété	**AR(1)**	**VAR(1)**
Équation	$y_t = \phi_0 + \phi_1 y_{t-1} + \varepsilon_t$	$\mathbf{y}_t = \mathbf{\Phi}_0 + \mathbf{\Phi}_1 \mathbf{y}_{t-1} + \varepsilon_t$
Moyenne	$\frac{\phi_0}{1-\phi_1}$	$(\mathbf{I}_k - \mathbf{\Phi}_1)^{-1}\mathbf{\Phi}_0$
Variance	$\frac{\sigma^2}{1-\phi_1^2}$	$(\mathbf{I} - \mathbf{\Phi}_1 \otimes \mathbf{\Phi}_1)^{-1}\text{vec}(\mathbf{\Sigma})$
Autocovariance s	$\gamma_s = \phi_1^s V[y_t]$	$\mathbf{\Gamma}_s = \mathbf{\Phi}_1^s V[\mathbf{y}_t]$
Autocovariance $-s$	$\gamma{-s} = \phi_1^s V[y_t]$	$\mathbf{\Gamma}{-s} = V[\mathbf{y}_t]\mathbf{\Phi}_1^{s\prime}$

Les autocovariances des processus vectoriels ne sont pas symétriques, mais $\mathbf{\Gamma}_s = \mathbf{\Gamma}'_{-s}$

Stationnarité

- AR(1) : $|\phi_1| < 1$
- VAR(1) : $|\lambda_i| < 1$ où λ_i sont les valeurs propres de $\mathbf{\Phi}_1$

VAR – Relation PIB / Chômage

Modèle

$$\begin{pmatrix} \text{PIB}_t \\ \text{CHO}_t \end{pmatrix} = \begin{pmatrix} 0.547^{\star\star\star} \\ 0.049^{\star} \end{pmatrix} + \begin{pmatrix} 0.182^{\star\star} & -0.639^{\star\star\star} \\ -0.096^{\star\star\star} & 0.507^{\star\star\star} \end{pmatrix} \begin{pmatrix} \text{PIB}_{t-1} \\ \text{CHO}_{t-1} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1,t} \\ \varepsilon_{2,t} \end{pmatrix}$$

Significance : $\star\star\star$: 1%, $\star\star$: 5%, $\star$: 10%

Modèles

Modèle du PIB

$$\text{PIB}_t = \phi_{01} + \phi_{11,1}\text{PIB}_{t-1} + \phi_{12,1}\text{CHO}_{t-1} + \varepsilon_{1,t}$$

Modèle du Chomage

$$\text{CHO}_t = \phi_{02} + \phi_{21,1}\text{PIB}_{t-1} + \phi_{22,1}\text{CHO}_{t-1} + \varepsilon_{2,t}$$

Estimations VAR(1)

$$\text{PIB}_t = 0.547^{***} + 0.182^{**}\text{PIB}_{t-1} - 0.639^{***}\text{CHO}_{t-1} + \varepsilon_{1,t}$$

$$\text{CHO}_t = 0.049^{\star} - 0.096^{***}\text{PIB}_{t-1} + 0.507^{***}\text{CHO}_{t-1} + \varepsilon_{2,t}$$

Estimations AR(1)

$$\text{PIB}_t = 0.648^{***} + 0.414^{***}\text{PIB}_{t-1} + \varepsilon_{1,t}$$

$$\text{CHO}_t = -0.003 + 0.692^{***}\text{CHO}_{t-1} + \varepsilon_{2,t}$$

Données

y_1 : **PIB**

y_2 : **Chomâge**

Pays : **USA**

Période : **jan. 1980 - déc. 2019**

Fréquence : **trimestrielle**

Les données – Obtention

```r
start_date <- as.Date("1980-01-01")
#start_date <- as.Date("1957-01-01")
end_date <- as.Date("2019-12-31")
#end_date <- as.Date("2024-12-31")

# 1. Télécharger et transormer les données FRED
gdp_data <- fredr(series_id = "GDPC1",
                  observation_start = start_date,
                  observation_end = end_date, frequency = "q")
unemp_data <- fredr(series_id = "UNRATE",
                    observation_start = start_date,
                    observation_end = end_date, frequency = "q")
```

Graphs – données brutes

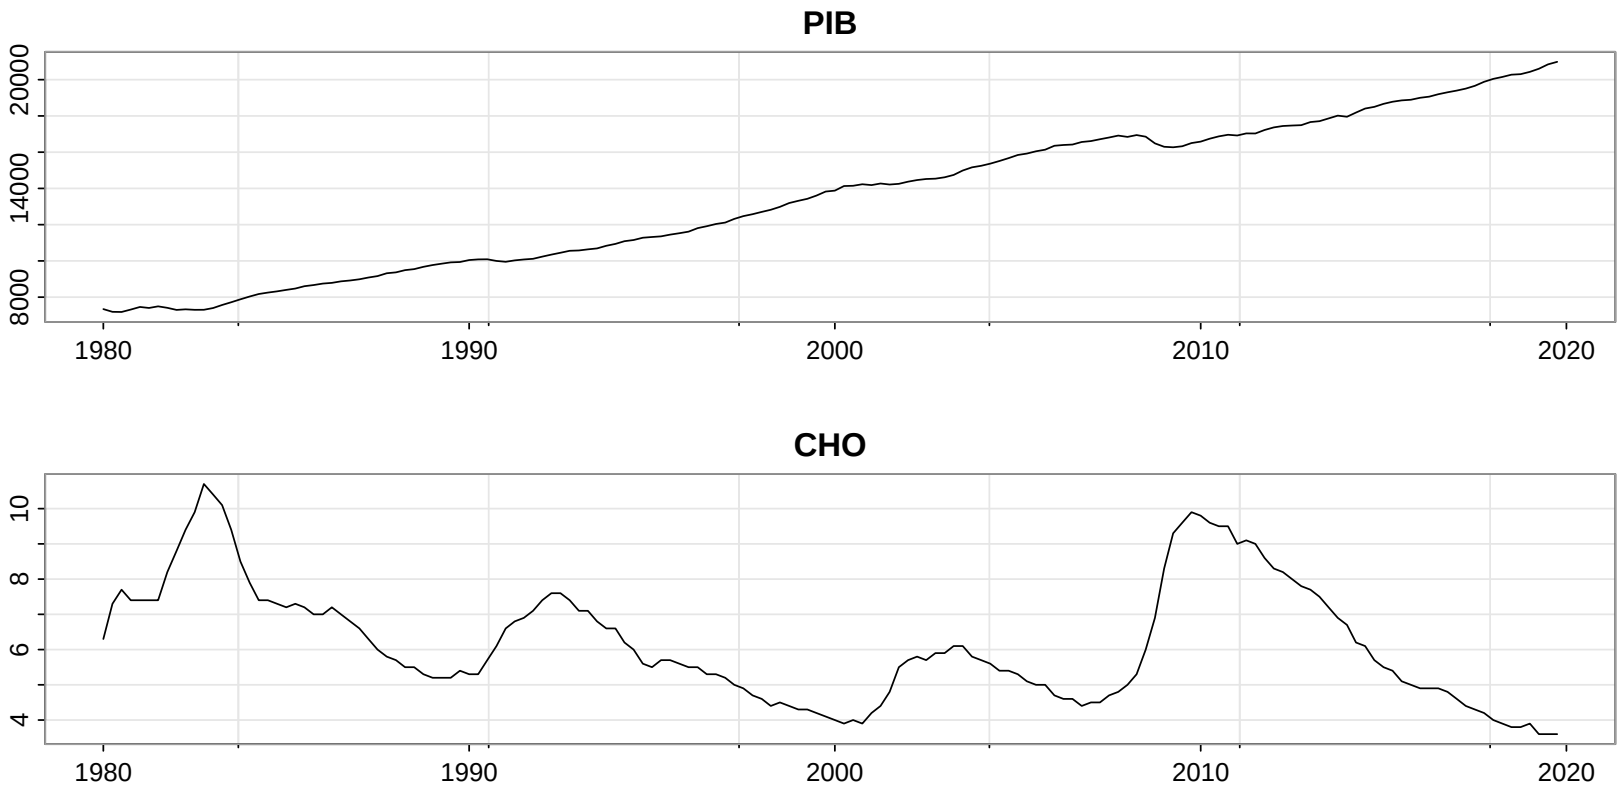

Les données – Manipulation

```r
# merge les deux variables dans une data.frame
data <- merge(gdp_data[, c("date", "value")],
              unemp_data[, c("date", "value")],
              by = "date", suffixes = c("_gdp", "_unemp"))
colnames(data) <- c("date", "gdp", "unemp")

# transformation des variables
data <- data %>%
  mutate(log_gdp = log(gdp), unemp = unemp) %>%
  select(date, log_gdp, unemp)

# s'assurer que les données sont stationnaires (différencier si nécessaire)
data_diff <- data %>%
  mutate(d_log_gdp = c(NA, diff(log_gdp)),
         d_unemp = c(NA, diff(unemp))) %>%
  na.omit()

# autre méthode pour transformer les données (à faire).
```

Les données – Tester la stationarité

PIB – log et diff(log)

```r
tseries::adf.test(data$log_gdp)
```

```
##
##  Augmented Dickey-Fuller Test
##
## data:  data$log_gdp
## Dickey-Fuller = -1.3962, Lag order = 5, p-value = 0.8282
## alternative hypothesis: stationary
```

```r
tseries::adf.test(data_diff$d_log_gdp)
```

```
##
##  Augmented Dickey-Fuller Test
##
## data:  data_diff$d_log_gdp
## Dickey-Fuller = -4.3656, Lag order = 5, p-value = 0.01
## alternative hypothesis: stationary
```

Les données – Tester la stationarité

CHO – taux et variation de taux

```r
tseries::adf.test(data$unemp)
```

```
##
##  Augmented Dickey-Fuller Test
##
## data:  data$unemp
## Dickey-Fuller = -2.5066, Lag order = 5, p-value = 0.3651
## alternative hypothesis: stationary
```

```r
tseries::adf.test(data_diff$d_unemp)
```

```
##
##  Augmented Dickey-Fuller Test
##
## data:  data_diff$d_unemp
## Dickey-Fuller = -3.8569, Lag order = 5, p-value = 0.01802
## alternative hypothesis: stationary
```

Les modèles – Estimation VAR(1) vs AR(1)

```r
# 2. Estimation des modèles
# (a) Modèle VAR(1) multivarié
data_diff$d_log_gdp <- data_diff$d_log_gdp*100
# *100 pour etre en % et coller à l'echelle de la variation du taux de chomage

var_model <- vars::VAR(data_diff[, c("d_log_gdp", "d_unemp")],
                       p = 1, type = "const")

# (b) Modèles AR(1) univariés
ar_gdp <- arima(data_diff$d_log_gdp, order = c(1, 0, 0))
ar_unemp <- arima(data_diff$d_unemp, order = c(1, 0, 0))
```

VAR(1) – Résultats d'estimation

```r
# 3. Analyse des résultats
# Résultats du VAR(1)

# lancer tout de meme summary dans le rmd
# summary(var_model)

coeftest(var_model)
```

```
##
## t test of coefficients:
##
##                          Estimate Std. Error t value  Pr(>|t|)
## d_log_gdp:(Intercept)   0.546785   0.074933  7.2970 1.430e-11 ***
## d_log_gdp:d_log_gdp.l1  0.182007   0.091499  1.9892  0.048442 *
## d_log_gdp:d_unemp.l1   -0.639115   0.202632 -3.1541  0.001934 **
## d_unemp:(Intercept)     0.048835   0.027895  1.7507  0.081981 .
## d_unemp:d_log_gdp.l1   -0.096275   0.034062 -2.8265  0.005327 **
## d_unemp:d_unemp.l1      0.507314   0.075432  6.7254 3.178e-10 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Graph des résidus

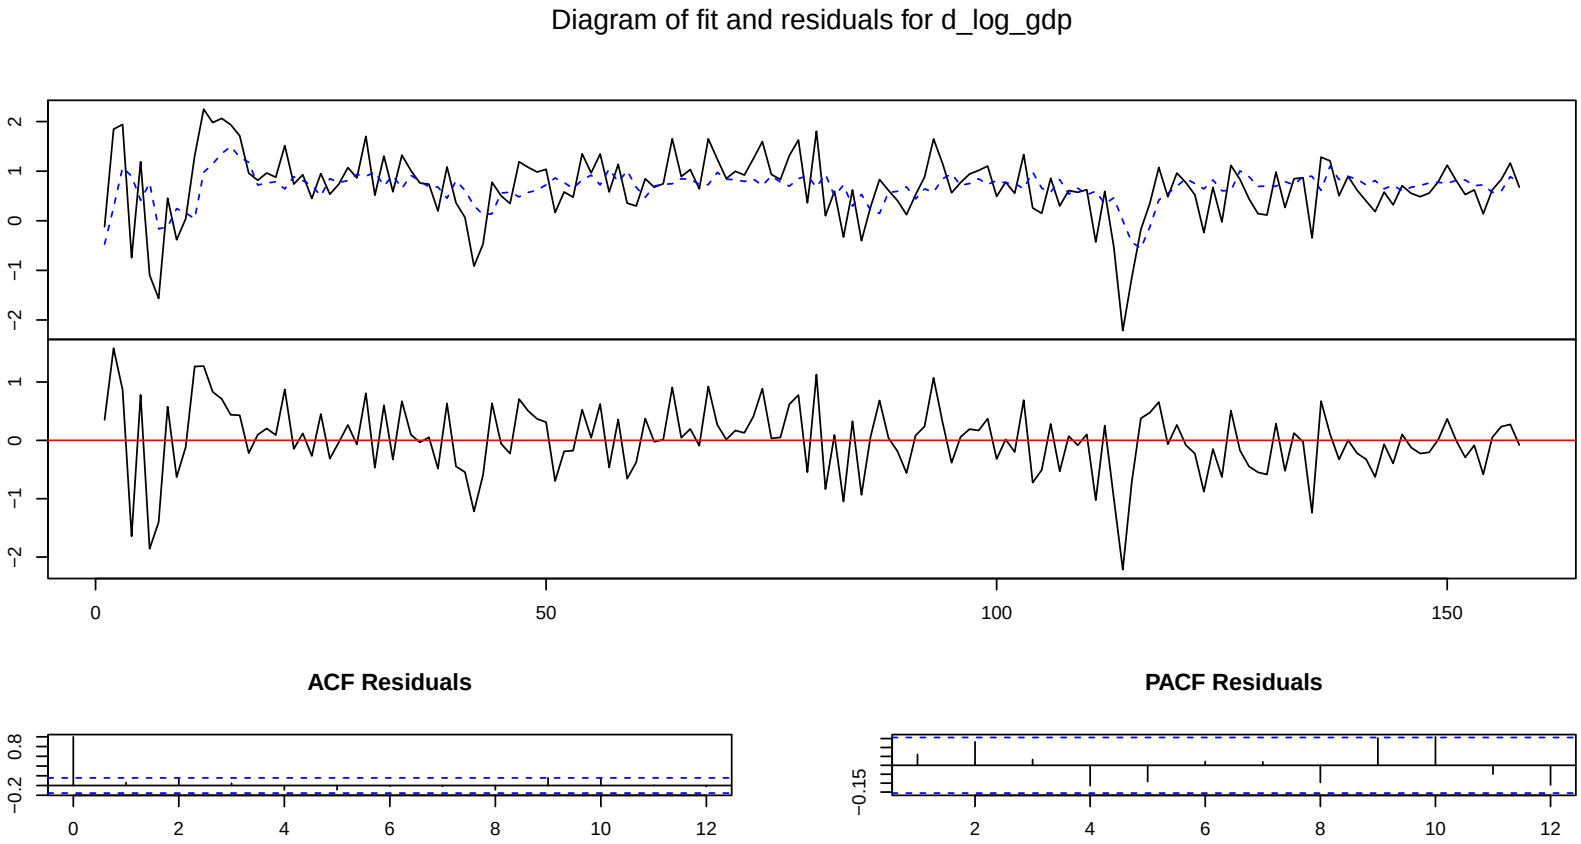

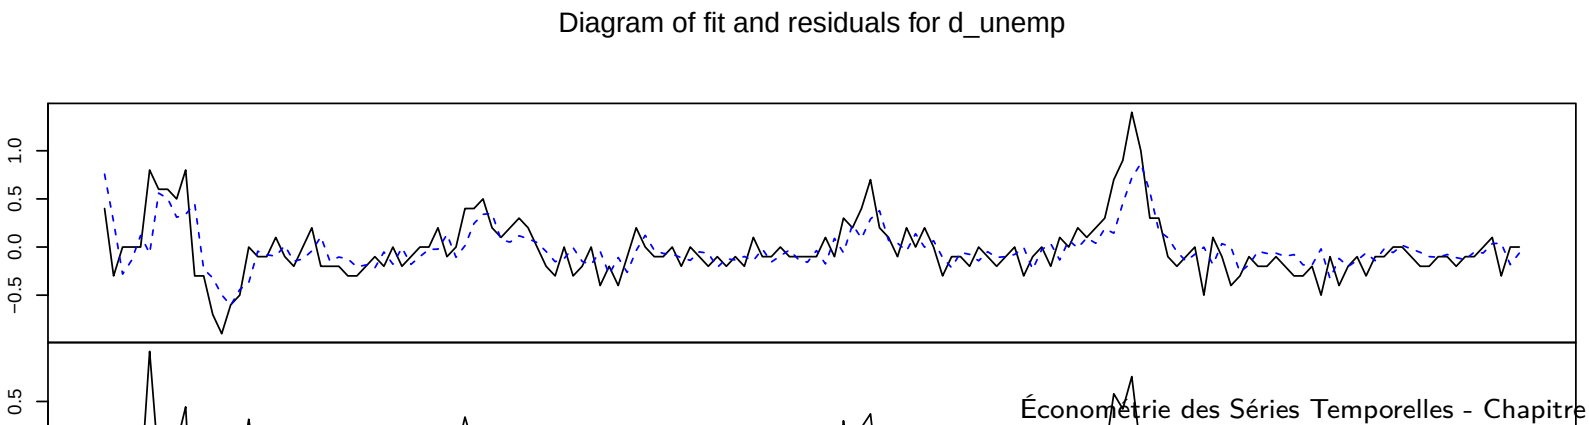

ACF Résidus

```r
acf(residuals(var_model))
```

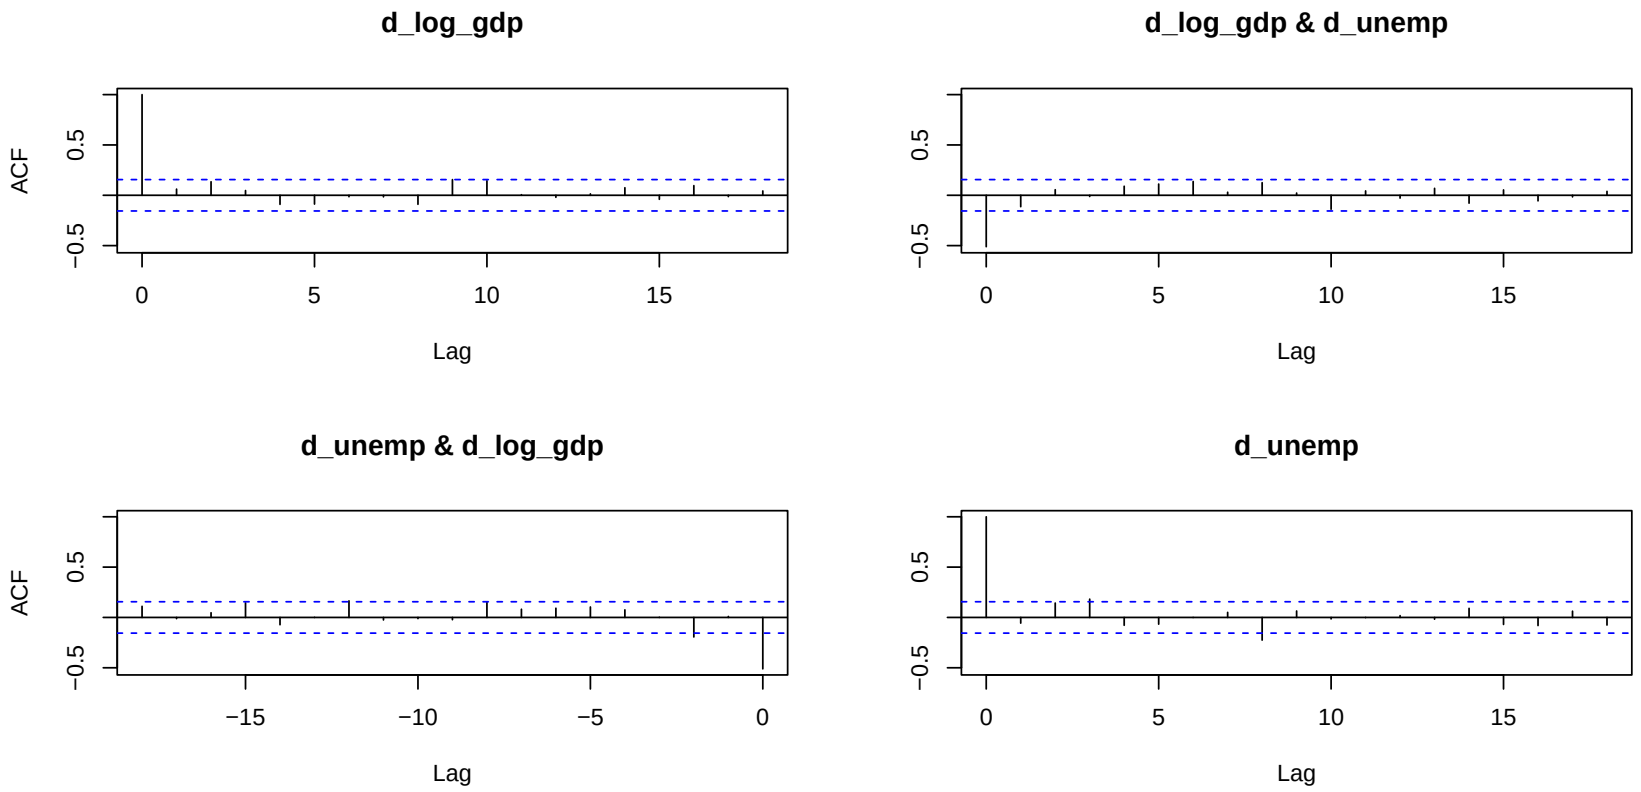

PACF Résidus

```r
pacf(residuals(var_model))
```

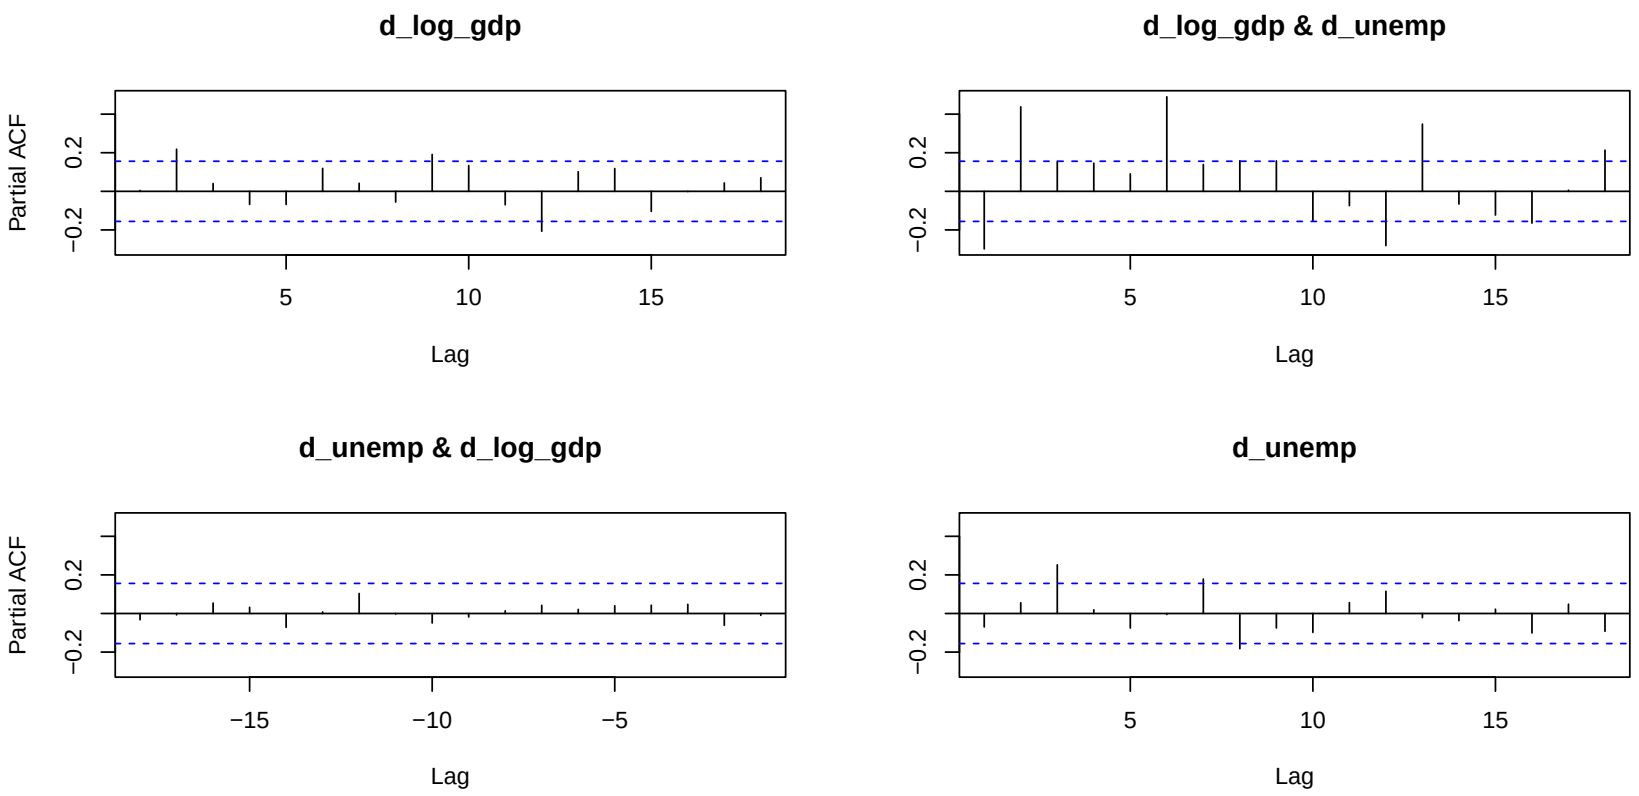

AR(1) – Résultats d'estimation

```r
# Résultats des modèles AR(1)
coeftest(ar_gdp)
```

```
##
## z test of coefficients:
##
##           Estimate Std. Error z value  Pr(>|z|)
## ar1       0.413760   0.076315  5.4217 5.903e-08 ***
## intercept 0.648535   0.085898  7.5501 4.350e-14 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```r
coeftest(ar_unemp)
```

```
##
## z test of coefficients:
##
##             Estimate Std. Error z value Pr(>|z|)
## ar1        0.6918376  0.0600663 11.5179   <2e-16 ***
## intercept -0.0027798  0.0589276 -0.0472   0.9624
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Résidus VAR(1) vs AR(1)

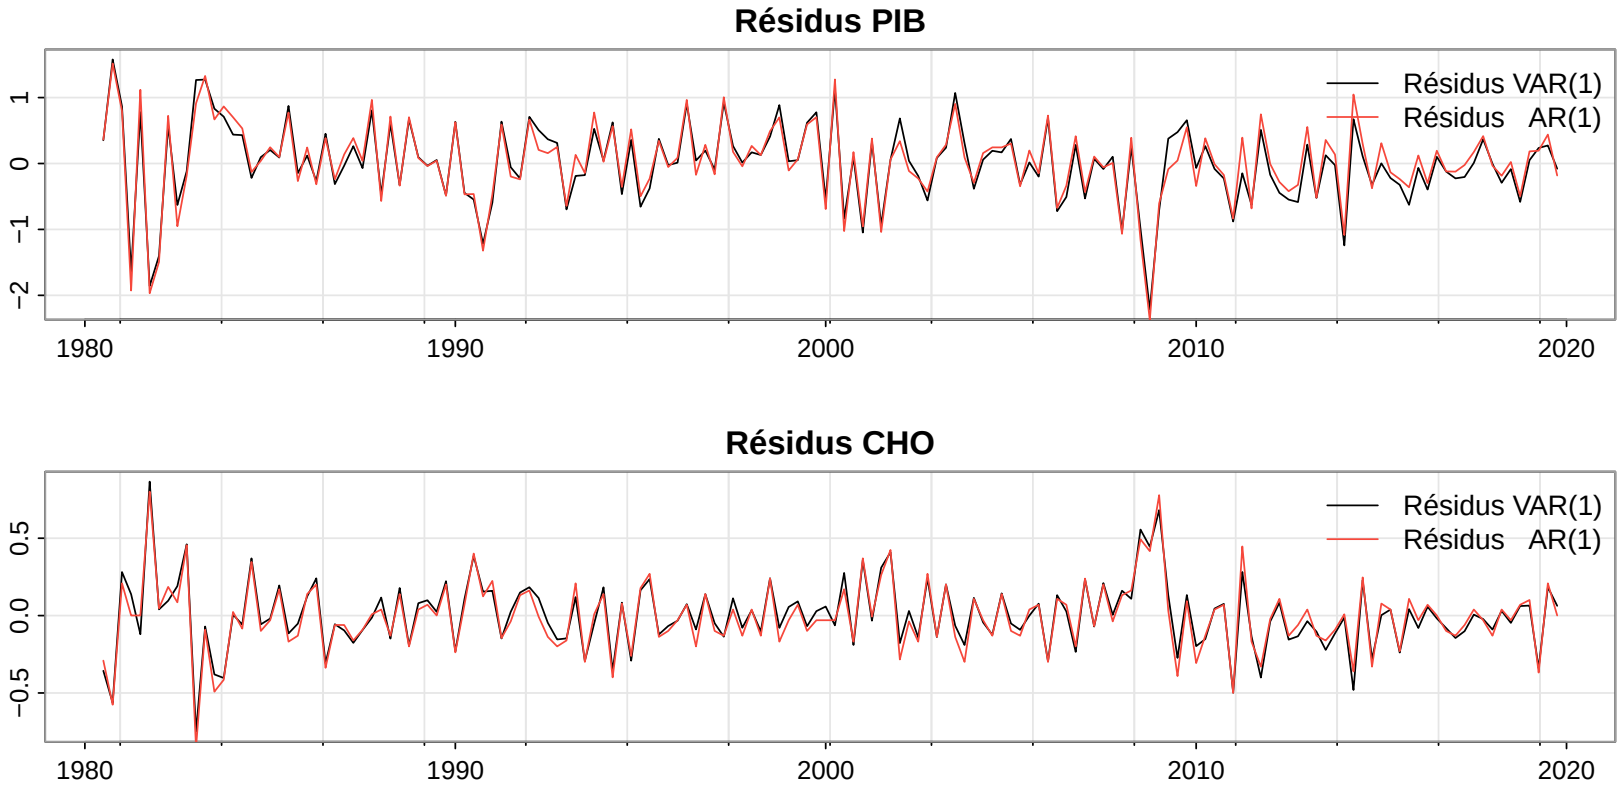

Prévision VAR(1)

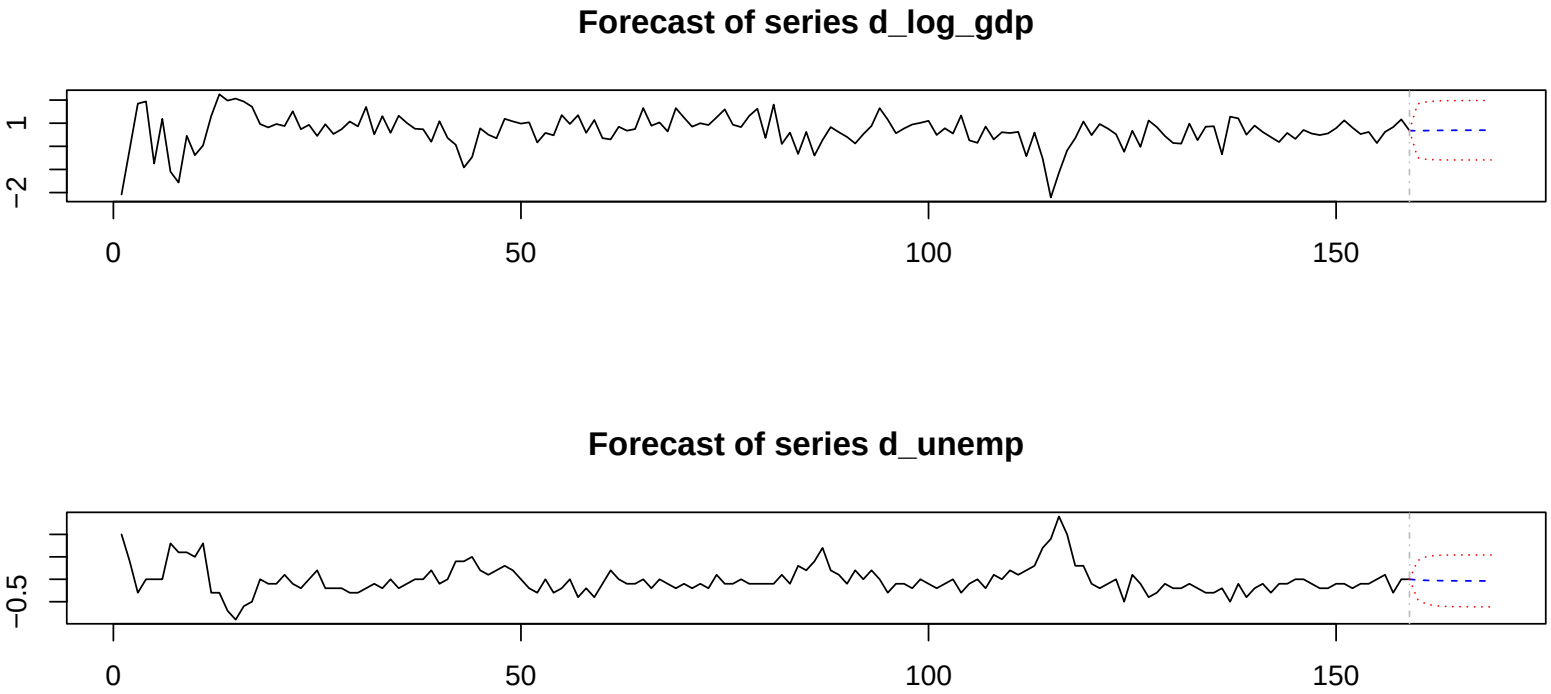

Prévision AR(1)

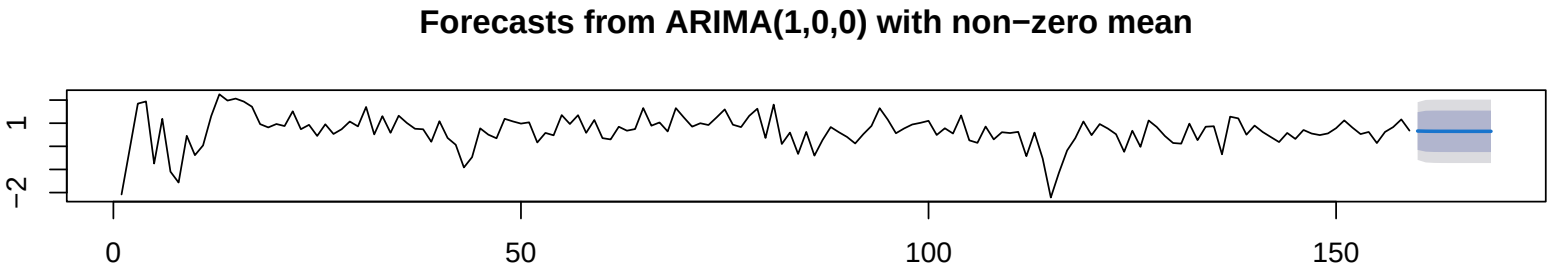

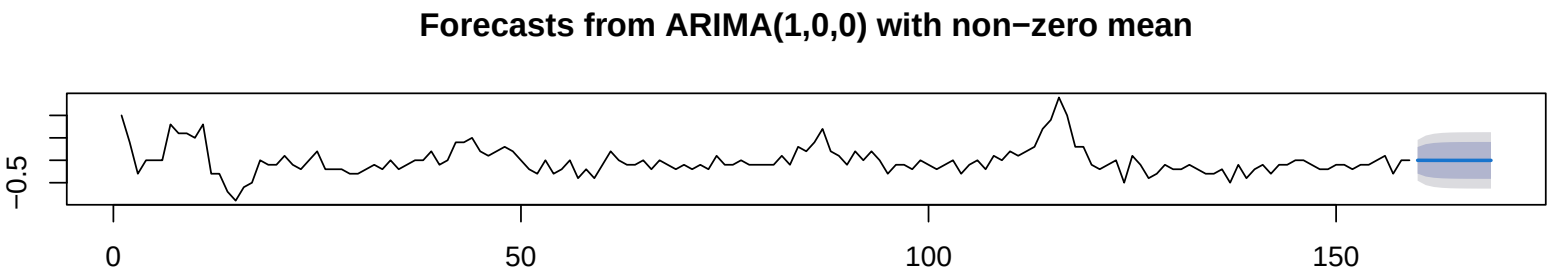

Politique monétaire - VAR

~ Taylor Rule : Chomage, Fed Funds, Inflation

y_1 : **Chômage**
y_2 : **Fed Funds**
y_3 : **Inflation**
Pays : **USA**
Période : **jan. 1957 - déc. 2019**
Fréquence : **trimestrielle**

```
start_date <- as.Date("1957-01-01")
end_date <- as.Date("1999-12-31")
# start_date <- as.Date("1980-01-01")
# end_date <- as.Date("2019-12-31")

UNRATE <- fredr(series_id = "UNRATE",
                observation_start = start_date,
                observation_end = end_date, frequency = "q")
DFF <- fredr(series_id = "DFF",
             observation_start = start_date,
             observation_end = end_date, frequency = "q")
GDPDEF <- fredr(series_id = "GDPDEF",
                observation_start = start_date,
                observation_end = end_date, frequency = "q")
```

Stationarité – visuelle

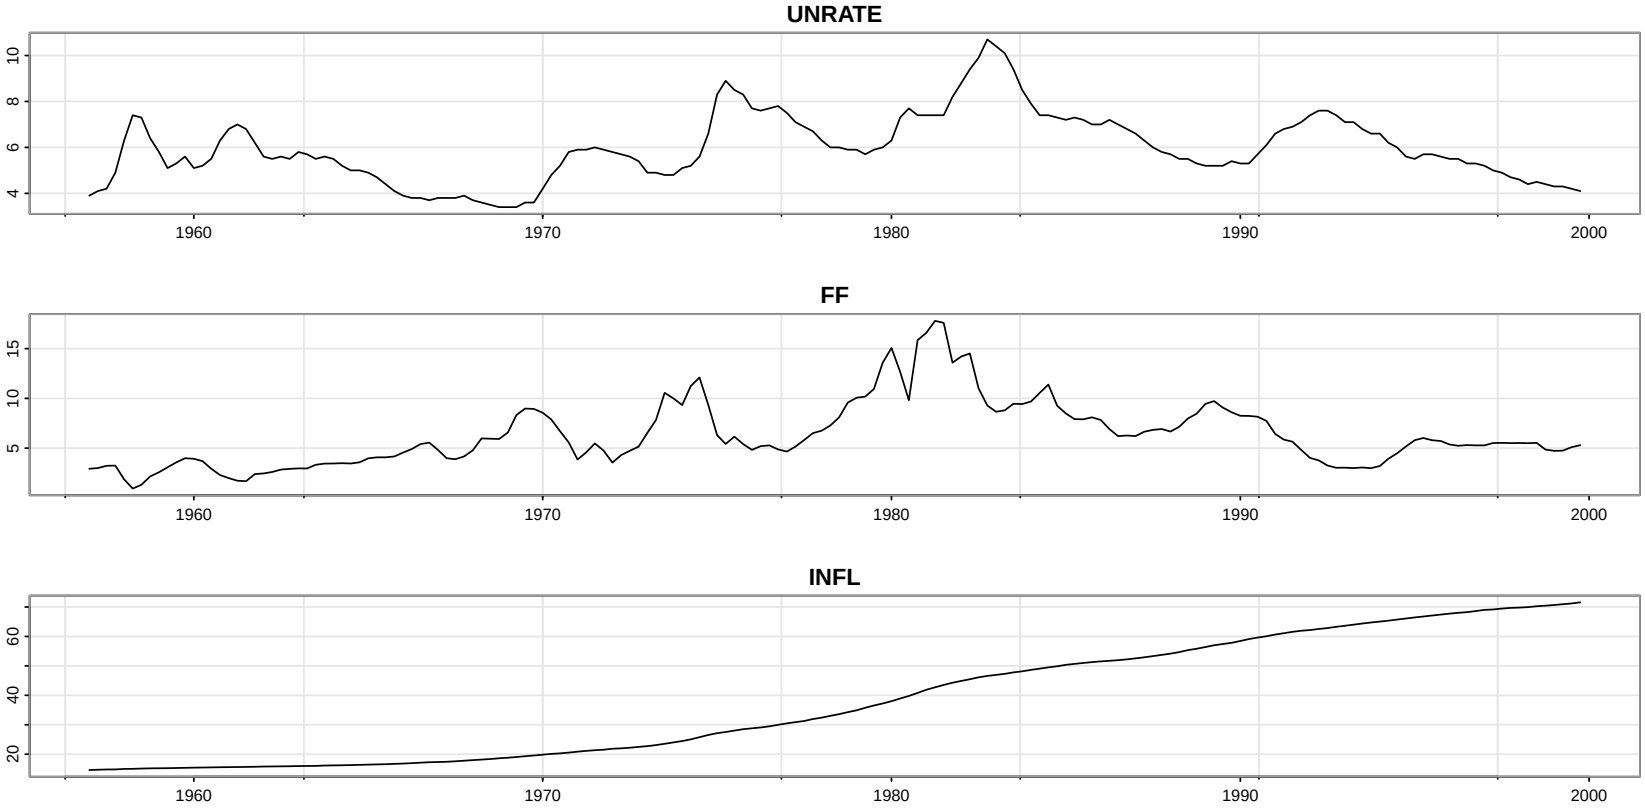

Stationarité – test

```r
adf_unrate <- tseries::adf.test(UNRATE$value)
adf_dff <- tseries::adf.test(DFF$value)
adf_gdpdef <- tseries::adf.test(GDPDEF$value)

adf_values <- data.frame(
  Série = c("UNRATE", "DFF", "GDPDEF"),
  `Statistique ADF` = c(adf_unrate$statistic,
                        adf_dff$statistic,
                        adf_gdpdef$statistic),
  `p-value` = c(adf_unrate$p.value,
                adf_dff$p.value,
                adf_gdpdef$p.value)
)
adf_values
```

```
##    Série Statistique.ADF    p.value
## 1 UNRATE       -2.355513 0.42780874
## 2    DFF       -3.150157 0.09839603
## 3 GDPDEF       -2.630979 0.31277964
```

Différenciation des séries

```r
# on différencie avec des méthodes qui maintiennent
# une "cohérence" des nouvelles variables
UNRATE.d <- na.omit(diff(UNRATE$value))
DFF.d <- na.omit(diff(DFF$value))
GDPDEF.d <- na.omit((log(diff(GDPDEF$value))))
# test stationarité
adf_unrate_d <- tseries::adf.test(UNRATE.d)
adf_dff_d <- tseries::adf.test(DFF.d)
adf_gdpdef_d <- tseries::adf.test(GDPDEF.d)

adf_values_d <- data.frame(
  Série = c("UNRATE", "DFF", "GDPDEF"),
  `Statistique ADF` = c(adf_unrate_d$statistic,
                        adf_dff_d$statistic,
                        adf_gdpdef_d$statistic),
  `p-value` = c(adf_unrate_d$p.value,
                adf_dff_d$p.value,
                adf_gdpdef_d$p.value)
)
adf_values_d
```

```
##    Série Statistique.ADF   p.value
## 1 UNRATE       -5.218266 0.0100000
## 2    DFF       -5.207432 0.0100000
## 3 GDPDEF       -1.165658 0.9093566
```

Graph de la série $I(2) \rightarrow I(1) \rightarrow I(0)$

```r
tsplot(GDPDEF.d)
```

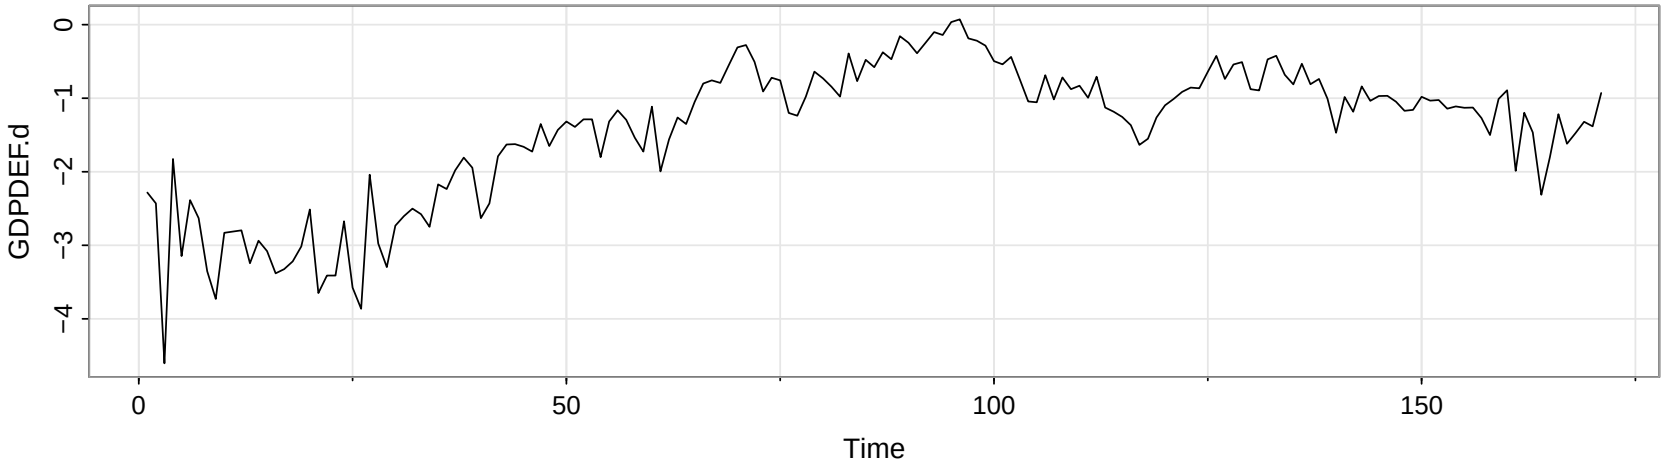


```r
# GDPDEF.d n'est toujours pas stationnaire : on différencie une seconde fois
GDPDEF.dd <- na.omit(diff((log(diff(GDPDEF$value)))))
# test stationarité
tseries::adf.test(diff(GDPDEF.dd))
```

```
##
##  Augmented Dickey-Fuller Test
##
## data:  diff(GDPDEF.dd)
## Dickey-Fuller = -10.4, Lag order = 5, p-value = 0.01
## alternative hypothesis: stationary
```

Graph des séries stationnaires

```r
par(mfrow=c(3,1))
tsplot(UNRATE.d)
tsplot(DFF.d)
tsplot(GDPDEF.dd)
```

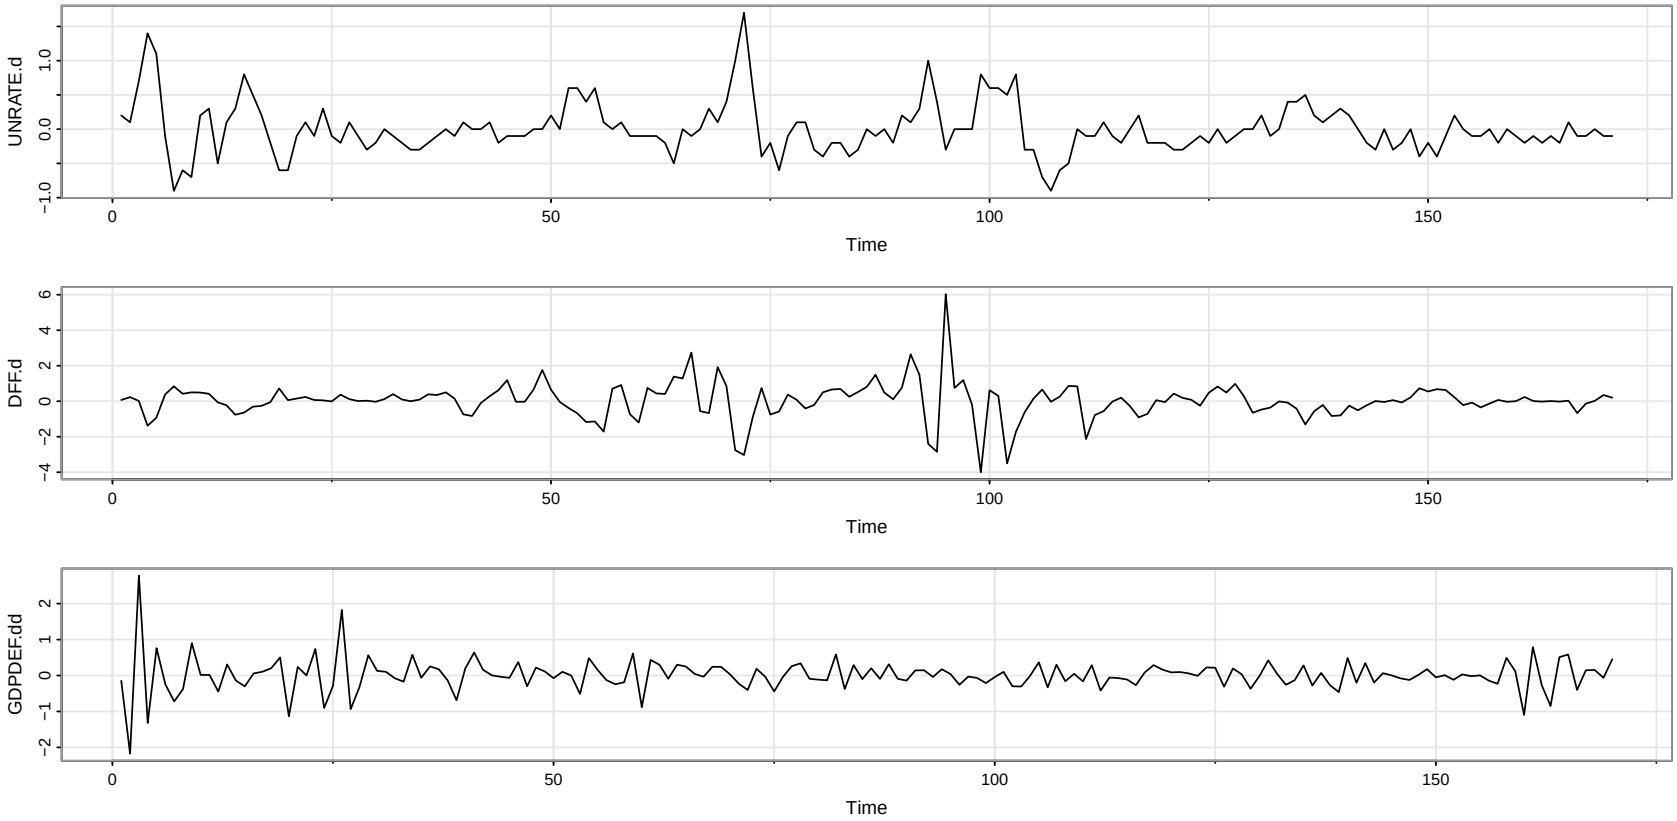

Estimation VAR(1) – UNRATE, FF, INF

```r
PolMon <- VAR(cbind(UNRATE.d, DFF.d, GDPDEF.dd), type = "none", p = 1)
# PolMon <- VAR(cbind(UNRATE.d, DFF.d, GDPDEF.dd), type = "none", p = 4)

# summary(PolMon)
coef(PolMon)
```

```
## $UNRATE.d
##                 Estimate Std. Error  t value     Pr(>|t|)
## UNRATE.d.l1  0.65596501 0.06919730 9.479633 2.512014e-17
## DFF.d.l1     0.03234603 0.02530148 1.278424 2.028737e-01
## GDPDEF.dd.l1 0.05270480 0.04886464 1.078588 2.823270e-01
##
## $DFF.d
##                  Estimate Std. Error    t value     Pr(>|t|)
## UNRATE.d.l1  -0.79875010 0.22816004 -3.5008325 0.0005949147
## DFF.d.l1      0.06938984 0.08342504  0.8317628 0.4067305799
## GDPDEF.dd.l1  0.02928980 0.16111840  0.1817905 0.8559675801
##
## $GDPDEF.dd
##                   Estimate Std. Error    t value     Pr(>|t|)
## UNRATE.d.l1  -0.055376927 0.09655546 -0.5735245 5.670611e-01
## DFF.d.l1      0.003746848 0.03530479  0.1061286 9.156077e-01
## GDPDEF.dd.l1 -0.479475102 0.06818399 -7.0320779 4.973776e-11
```

Modèle trivarié VAR(1) estimé

$$UNRATE_t = 0.656^{***} UNRATE_{t-1} + 0.032 FF_{t-1} + 0.053 INF_{t-1} + \varepsilon_{UNRATE,t}$$

$$FF_t = -0.799^{***} UNRATE_{t-1} + 0.069 FF_{t-1} + 0.029 INF_{t-1} + \varepsilon_{FF,t}$$

$$INF_t = -0.055 UNRATE_{t-1} + 0.004 FF_{t-1} - 0.479^{***} INF_{t-1} + \varepsilon_{INF,t}$$

En pratique, pour vérifier la Taylor Rule on applique un VAR structurel (SVAR) afin d'imposer une relation ***structurelle***

Graph $\mathbf{y}_t, \widehat{\mathbf{y}}_t, \widehat{\varepsilon}_t$, *ACF* et *PACF* de $\widehat{\varepsilon}_t$

Pour obtenir les 3 graphiques aller sur le .rmd

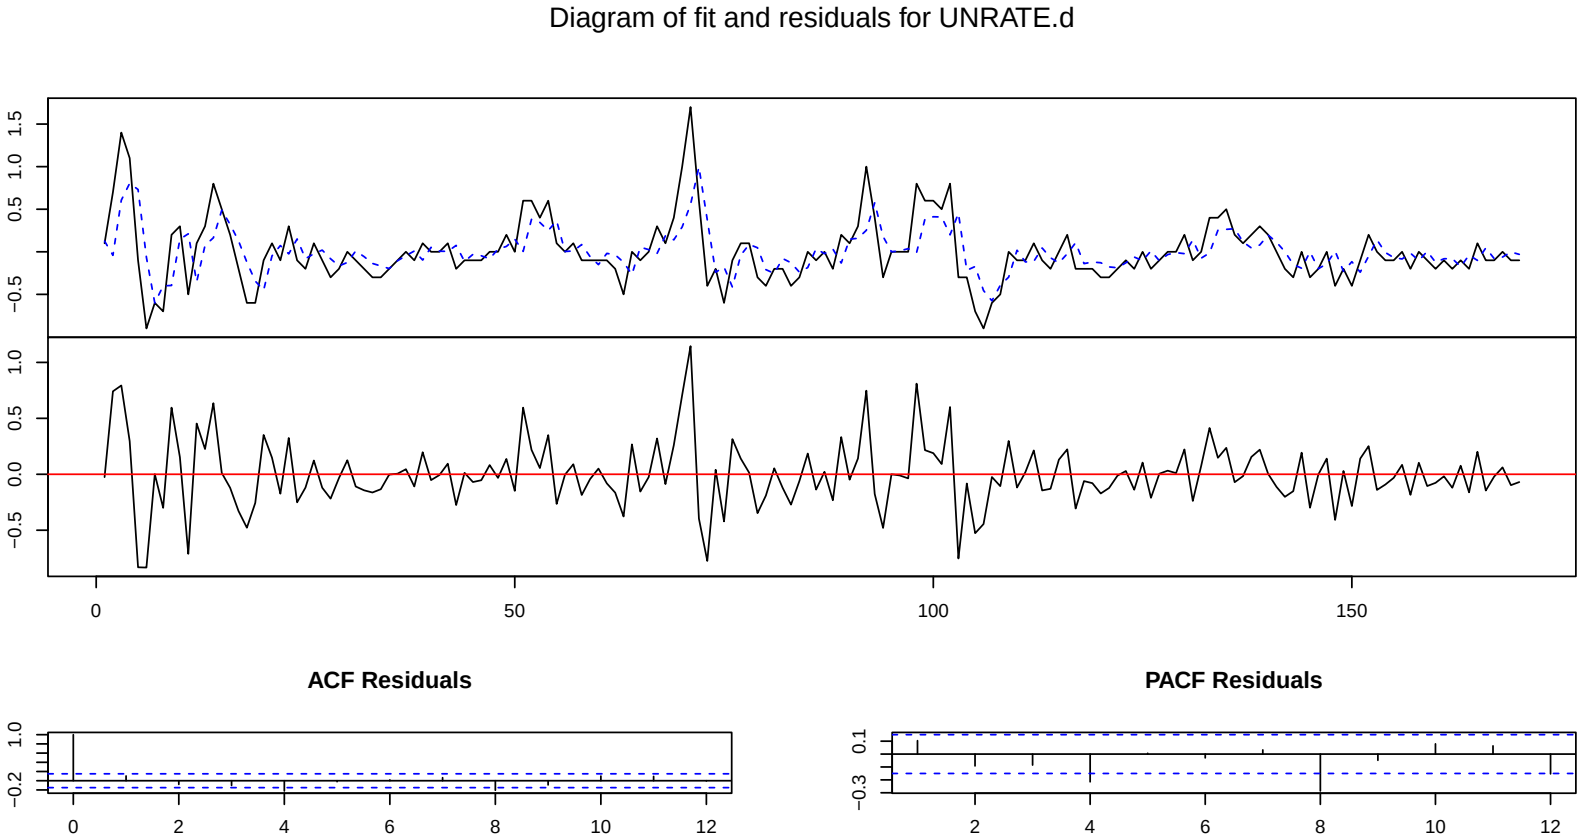

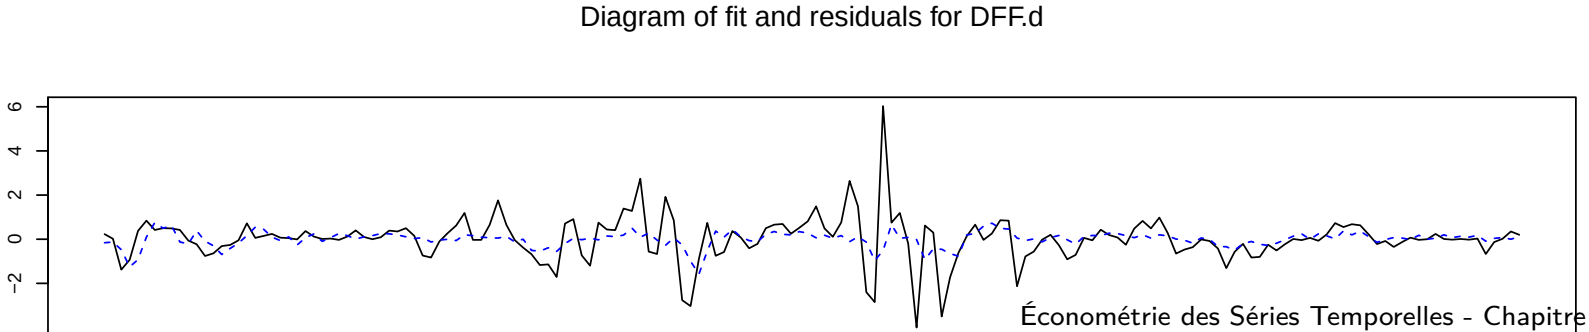

VAR(1) standardisé

```r
# Standardisation des séries
UNRATE.d.std <- scale(UNRATE.d)  # Moyenne 0, variance 1
DFF.d.std <- scale(DFF.d)        # Moyenne 0, variance 1
GDPDEF.dd.std <- scale(GDPDEF.dd)  # Moyenne 0, variance 1

# Modèle VAR avec données standardisées
PolMon.std <- VAR(cbind(UNRATE.d.std[-1], DFF.d.std[-1], GDPDEF.dd.std), type =
# summary(PolMon.std)
coef(PolMon.std)
```

```
## $y1
##          Estimate Std. Error    t value     Pr(>|t|)
## y1.l1  0.65897262 0.06975889  9.4464320 3.218634e-17
## y2.l1  0.09734743 0.06967117  1.3972413 1.642058e-01
## y3.l1 -0.04620755 0.06149536 -0.7513989 4.534766e-01
##
## $y2
##          Estimate Std. Error    t value     Pr(>|t|)
## y1.l1 -0.29501021 0.08371131 -3.5241382 0.0005490911
## y2.l1  0.06777718 0.08360603  0.8106734 0.4187139941
## y3.l1  0.02258793 0.07379500  0.3060903 0.7599194395
##
## $y3
##          Estimate Std. Error   t value     Pr(>|t|)
## y1.l1  0.02397656 0.07725677  0.310349 7.566849e-01
## y2.l1  0.11286207 0.07715962  1.462709 1.454378e-01
## y3.l1 -0.48236706 0.06810506 -7.082691 3.820486e-11
```

VAR(P) est en réalité un VAR(1)

Forme compagnon :

$$\mathbf{y}_t = \Phi_0 + \Phi_1 \mathbf{y}_{t-1} + \Phi_2 \mathbf{y}_{t-2} + \ldots + \Phi_P \mathbf{y}_{t-P} + \varepsilon_t$$

Reformuler en un seul VAR(1) où $\mu = E[\mathbf{y}_t] = (I - \Phi_1 - \ldots - \Phi_P)^{-1}\Phi_0$

$$\mathbf{z}_t = \Upsilon \mathbf{z}_{t-1} + \boldsymbol{\xi}_t$$

$$\mathbf{z}_t = \begin{pmatrix} \mathbf{y}_t - \boldsymbol{\mu} \\ \mathbf{y}_{t-1} - \boldsymbol{\mu} \\ \vdots \\ \mathbf{y}_{t-P+1} - \boldsymbol{\mu} \end{pmatrix}, \Upsilon = \begin{pmatrix} \Phi_1 & \Phi_2 & \Phi_3 & \ldots & \Phi_{P-1} & \Phi_P \\ I_k & 0 & 0 & \ldots & 0 & 0 \\ 0 & I_k & 0 & \ldots & 0 & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & 0 & \ldots & I_k & 0 \end{pmatrix}$$

- Tous les résultats peuvent être directement appliqués à la forme compagnon.
- Peut également être utilisé pour transformer AR(P) en VAR(1)

Revisiter les prévisions univariées

- Considérons l'AR(1) standard

$$y_t = \phi_0 + \phi_1 y_{t-1} + \varepsilon_t$$

- Prévision optimale à 1 étape :

$$\begin{aligned} \mathrm{E}_t\left[y_{t+1}\right] &= \mathrm{E}_t\left[\phi_0\right] + \mathrm{E}_t\left[\phi_1 y_t\right] + \mathrm{E}_t\left[\varepsilon_{t+1}\right] \\ &= \phi_0 + \phi_1 y_t + 0 \end{aligned}$$

- Prévision optimale à 2 étapes :

$$\begin{aligned} \mathrm{E}_t\left[y_{t+2}\right] &= \mathrm{E}_t\left[\phi_0\right] + \mathrm{E}_t\left[\phi_1 y_{t+1}\right] + \mathrm{E}_t\left[\varepsilon_{t+2}\right] \\ &= \phi_0 + \phi_1 \mathrm{E}_t\left[y_{t+1}\right] + 0 \\ &= \phi_0 + \phi_1\left(\phi_0 + \phi_1 y_t\right) \\ &= \phi_0 + \phi_1\phi_0 + \phi_1^2 y_t \end{aligned}$$

- Prévision optimale à h étapes :

$$\mathrm{E}_t\left[y_{t+h}\right] = \sum_{i=0}^{h-1} \phi_1^i \phi_0 + \phi_1^h y_t$$

Prévisions avec VAR

- Identique au cas univarié

$$\mathbf{y}_t = \mathbf{\Phi}_0 + \mathbf{\Phi}_1 \mathbf{y}_{t-1} + \varepsilon_t$$

- Prévision optimale à 1 étape :

$$\begin{aligned} \mathrm{E}_t\left[\mathbf{y}_{t+1}\right] &= \mathrm{E}_t\left[\mathbf{\Phi}_0\right] + \mathrm{E}_t\left[\mathbf{\Phi}_1 \mathbf{y}_t\right] + \mathrm{E}_t\left[\varepsilon_{t+1}\right] \\ &= \mathbf{\Phi}_0 + \mathbf{\Phi}_1 \mathbf{y}_t + \mathbf{0} \end{aligned}$$

- Prévision optimale à h étapes :

$$\begin{aligned} \mathrm{E}_t\left[\mathbf{y}_{t+h}\right] &= \mathbf{\Phi}_0 + \mathbf{\Phi}_1 \mathbf{\Phi}_0 + \ldots + \mathbf{\Phi}_1^{h-1} \mathbf{\Phi}_0 + \mathbf{\Phi}_1^h \mathbf{y}_t \\ &= \sum_{i=0}^{h-1} \mathbf{\Phi}_1^i \mathbf{\Phi}_0 + \mathbf{\Phi}_1^h \mathbf{y}_t \end{aligned}$$

- Prévision de plus haut ordre peut être calculée de manière récursive

$$\mathrm{E}_t\left[\mathbf{y}_{t+h}\right] = \mathbf{\Phi}_0 + \mathbf{\Phi}_1 \mathrm{E}_t\left[\mathbf{y}_{t+h-1}\right] + \ldots + \mathbf{\Phi}_P \mathrm{E}_t\left[\mathbf{y}_{t+h-P}\right]$$

Qu'est-ce qui fait une bonne prévision ?

- Résidus de prévision

$$\hat{e}_{t+h|t} = y_{t+h} - \hat{y}_{t+h|t}$$

- Les résidus *ne sont pas* un bruit blanc
- Peut contenir une composante MA$(h-1)$
  - Erreur de prévision pour $y_{t+1} - \widehat{y}_{t+1|t-h+1}$ n'était pas connue au moment t.
- Tracez vos résidus
- ACF des résidus
- Régressions de Mincer-Zarnowitz
- Procédure à trois périodes
  - Échantillon d'entraînement : Utilisé pour construire le modèle
  - Échantillon de validation : Utilisé pour affiner le modèle
  - Échantillon d'évaluation : Test ultime, idéalement en une seule fois

Prévision multi-étapes

Deux méthodes

- Méthode itérative
  - Construire un modèle pour les prévisions à 1 étape

$$\mathbf{y}_t = \mathbf{\Phi}_0 + \mathbf{\Phi}_1 \mathbf{y}_{t-1} + \boldsymbol{\varepsilon}_t$$

  - Itérer la prévision jusqu'à la période h

$$\hat{\mathbf{y}}_{t+h|t} = \sum_{i=0}^{h-1} \mathbf{\Phi}_1^i \mathbf{\Phi}_0 + \mathbf{\Phi}_1^h \mathbf{y}_t$$

  - Utilise efficacement les informations
  - Impose beaucoup de structure au problème
- Méthode directe
  - Construire un modèle pour les prévisions à h étapes

$$\mathbf{y}_t = \mathbf{\Phi}_0 + \mathbf{\Phi}_h \mathbf{y}_{t-h} + \boldsymbol{\varepsilon}_t$$

  - Prévision directe en utilisant une méthode pseudo à 1 étape

$$\hat{\mathbf{y}}_{t+h|t} = \mathbf{\Phi}_0 + \mathbf{\Phi}_h \mathbf{y}_t$$

  - Robuste à certaines non-linéarités

Évaluation des prévisions multi-étapes

- L'évaluation des prévisions multi-étapes est identique à l'évaluation des prévisions à une étape avec une réserve
- Les erreurs de prévision à h étapes peuvent être corrélées avec toute erreur de prévision non connue au moment t

$$\hat{e}_{t+1|t-h+1}, \hat{e}_{t+2|t-h+2}, \ldots, \hat{e}_{t+h-1|t-1}$$

- Conduit à une structure MA$(h-1)$ dans les erreurs de prévision
- Solutions :
  - Utiliser une régression GMZ régulière avec un estimateur de covariance Newey-West

$$y_{t+h} - \hat{y}_{t+h|t} = \beta_1 + \beta_2 \hat{y}_{t+h|t} + \gamma \mathbf{x}_t + \eta_t$$

$$H_0 : \beta_1 = \beta_2 = \gamma = 0, H_1 : \beta_1 \neq 0 \cup \beta_2 \neq 0 \cup \gamma_j \neq 0 \quad \exists j$$

  - Modéliser explicitement le MA$(h-1)$ et utiliser un estimateur de covariance standard

$$y_{t+h} - \hat{y}_{t+h|t} = \beta_1 + \beta_2 \hat{y}_{t+h|t} + \gamma \mathbf{x}_t + \eta_t + \sum_{i=1}^{h-1} \theta_i \eta_{t-i}$$

Note : H_0 est la même ; n'impose pas de restriction sur θ

Exemple : VAR de Politique Monétaire

- Prévisions produites de manière itérative pour 1 à 8 trimestres à l'avance
- Benchmark (*bm*) de marche aléatoire (*Fixed Forecast*) ou de moyenne constante
- AR et VAR sélectionnent la longueur de décalage en utilisant BIC
- Forcer la réversion à la moyenne dans l'échantillon en utilisant un estimateur à 2 étapes
  1. Estimer la moyenne de l'échantillon, et soustraire pour produire $\tilde{\mathbf{y}}_t = \mathbf{y}_t - \hat{\boldsymbol{\mu}}$
  2. Estimer VAR *sans* constante

$$\tilde{\mathbf{y}}_t = \boldsymbol{\Phi}_1 \tilde{\mathbf{y}}_{t-1} + \ldots + \boldsymbol{\Phi}_P \tilde{\mathbf{y}}_{t-P} + \boldsymbol{\varepsilon}_t$$

  3. Prévision puis ajouter la moyenne dans l'échantillon

$$\mathrm{E}_t \left[\tilde{\mathbf{y}}_{t+h}\right] + \hat{\boldsymbol{\mu}}$$

- Évaluation basée sur MSE relatif :

$$\text{Rel. } \mathrm{MSE} = \frac{\mathrm{MSE}}{\mathrm{MSE}_{bm}}, \mathrm{MSE} = 1/(T-h-R) \sum_{t=R}^{T-h} \left(y_{t+h} - \hat{y}_{t+h|t}\right)^2$$

Exemple : VAR de Politique Monétaire

Horizon	Série	VAR		AR	
		Restreinte	Non restreinte	Restreinte	Non restreinte
1	Chômage	0.522	0.520	**0.507**	0.507
	Taux des fonds fédéraux	**0.887**	0.903	0.923	0.933
	Inflation	0.869	0.868	**0.839**	0.840
2	Chômage	0.716	**0.710**	0.717	0.718
	Taux des fonds fédéraux	**0.923**	0.943	1.112	1.130
	Inflation	1.082	1.081	1.031	**1.030**
4	Chômage	0.872	**0.861**	0.937	0.940
	Taux des fonds fédéraux	**0.952**	0.976	1.082	1.109
	Inflation	1.000	0.999	0.998	**0.998**
8	Chômage	0.820	**0.806**	0.973	0.979
	Taux des fonds fédéraux	**0.974**	1.007	1.062	1.110
	Inflation	1.001	1.000	0.998	**0.997**

Performances de prévision VAR vs AR

1. Le taux de chômage,
2. Le taux des Fed Funds,
3. L'inflation.

Les prévisions sont réalisées à partir de **50 % de l'échantillon disponible**, et les paramètres du modèle sont réestimés à chaque itération.
La précision des prévisions est mesurée par la **Mean Squared Error (MSE) hors échantillon**, comparée à celle d'un **modèle de référence** (random walk pour le Fed Funds rate et moyenne historique pour les autres variables).
Deux variantes du VAR sont testées :

- **Modèle restreint** : Forcé à converger vers la moyenne historique.
- **Modèle non restreint** : Estime librement les paramètres, y compris l'intercept.

Le VAR intègre des interactions entre plusieurs séries temporelles, offrant des prévisions plus précises que les modèles univariés dans 7 cas sur 12. Lorsqu'il n'est pas optimal, il reste compétitif.
En **politique monétaire** et plus généralement en macroéconomie, permet d'anticiper l'impact des chocs et améliorer la prise de décision.

Estimation

Estimation et Identification

- Identification univariée : Box-Jenkins
  - Utiliser ACF et PACF pour déterminer l'ordre de décalage AR et MA
  - Examiner les résidus
  - Principe de parcimonie
- L'autocorrélation d'un processus scalaire est définie

$$\rho_s = \frac{\gamma_s}{\gamma_0}$$

où γ_s est la $s^{\text{ème}}$ autocovariance
  - Coefficient de régression :

$$y_t = \mu + \rho_s y_{t-s} + \varepsilon_t$$

- Autocorrélation partielle ψ_s
  - Interprétation de régression de la $s^{\text{ème}}$ autocorrélation partielle :

$$y_t = \mu + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \ldots + \phi_{s-1} y_{t-s+1} + \psi_s y_{t-s} + \varepsilon_t$$

  - ψ est la $s^{\text{ème}}$ autocorrélation partielle

CCF et PCCF

(Fonction Cross Correlation) et (Fonction Cross Correlation Partielle)

- Équivalents multivariés
  - ACF et PACF ont les mêmes définitions de régression
  - Fonction de corrélation croisée

$$\rho_{xy,s} = \frac{\mathrm{E}\left[\left(x_t - \mu_x\right)\left(y_{t-s} - \mu_y\right)\right]}{\sqrt{\mathrm{V}\left[x_t\right]\mathrm{V}\left[y_t\right]}}$$

$$\rho_{yx,s} = \frac{\mathrm{E}\left[\left(y_t - \mu_y\right)\left(x_{t-s} - \mu_x\right)\right]}{\sqrt{\mathrm{V}\left[x_t\right]\mathrm{V}\left[y_t\right]}}$$

  - Généralement différent
  - Fonction de corrélation partielle croisée $\psi_{xy,s}$

$$\begin{aligned} x_t =& \phi_0 + \phi_{x1} x_{t-1} + \ldots + \phi_{xs-1} x_{t-(s-1)} \\ & + \phi_{y1} y_{t-1} + \ldots + \phi_{ys-1} y_{t-(s-1)} + \varphi_{xy,s} y_{t-s} + \varepsilon_{x,t} \end{aligned}$$

    - Peut aider à identifier l'ordre VAR
- Problème plus profond : trop nombreux et trop compliqués
- Solution simple : Sélection de modèle

Interprétation des CCF et PCCF

- y a une dynamique (Hétérogène) HAR et se "déverse" dans x

$$\begin{bmatrix} x_t \\ y_t \end{bmatrix} = \begin{bmatrix} 0.5 & 0.9 \\ .0 & 0.47 \end{bmatrix} \begin{bmatrix} x_{t-1} \\ y_{t-1} \end{bmatrix} + \sum_{i=2}^{5} \begin{bmatrix} 0 & 0 \\ 0 & 0.06 \end{bmatrix} \begin{bmatrix} x_{t-i} \\ y_{t-i} \end{bmatrix}$$

$$+ \sum_{j=6}^{22} \begin{bmatrix} 0 & 0 \\ 0 & 0.01 \end{bmatrix} \begin{bmatrix} x_{t-j} \\ y_{t-j} \end{bmatrix} + \begin{bmatrix} \varepsilon_{x,t} \\ \varepsilon_{y,t} \end{bmatrix}$$

détaillée par

$$\begin{bmatrix} x_t \\ y_t \end{bmatrix} = \underbrace{\begin{bmatrix} 0.5 & 0.9 \\ 0 & 0.47 \end{bmatrix} \begin{bmatrix} x_{t-1} \\ y_{t-1} \end{bmatrix}}_{\text{Dépendance immédiate sur } t-1} + \underbrace{\sum_{i=2}^{5} \begin{bmatrix} 0 & 0 \\ 0 & 0.06 \end{bmatrix} \begin{bmatrix} x_{t-i} \\ y_{t-i} \end{bmatrix}}_{\text{Effet de mémoire moyen terme (lags 2-5) sur } y_t}$$

$$+ \underbrace{\sum_{j=6}^{22} \begin{bmatrix} 0 & 0 \\ 0 & 0.01 \end{bmatrix} \begin{bmatrix} x_{t-j} \\ y_{t-j} \end{bmatrix}}_{\text{Effet de mémoire long terme (lags 6-22) sur } y_t} + \underbrace{\begin{bmatrix} \varepsilon_{x,t} \\ \varepsilon_{y,t} \end{bmatrix}}_{\text{Innovations}}$$

Graph des séries

- Données simulées

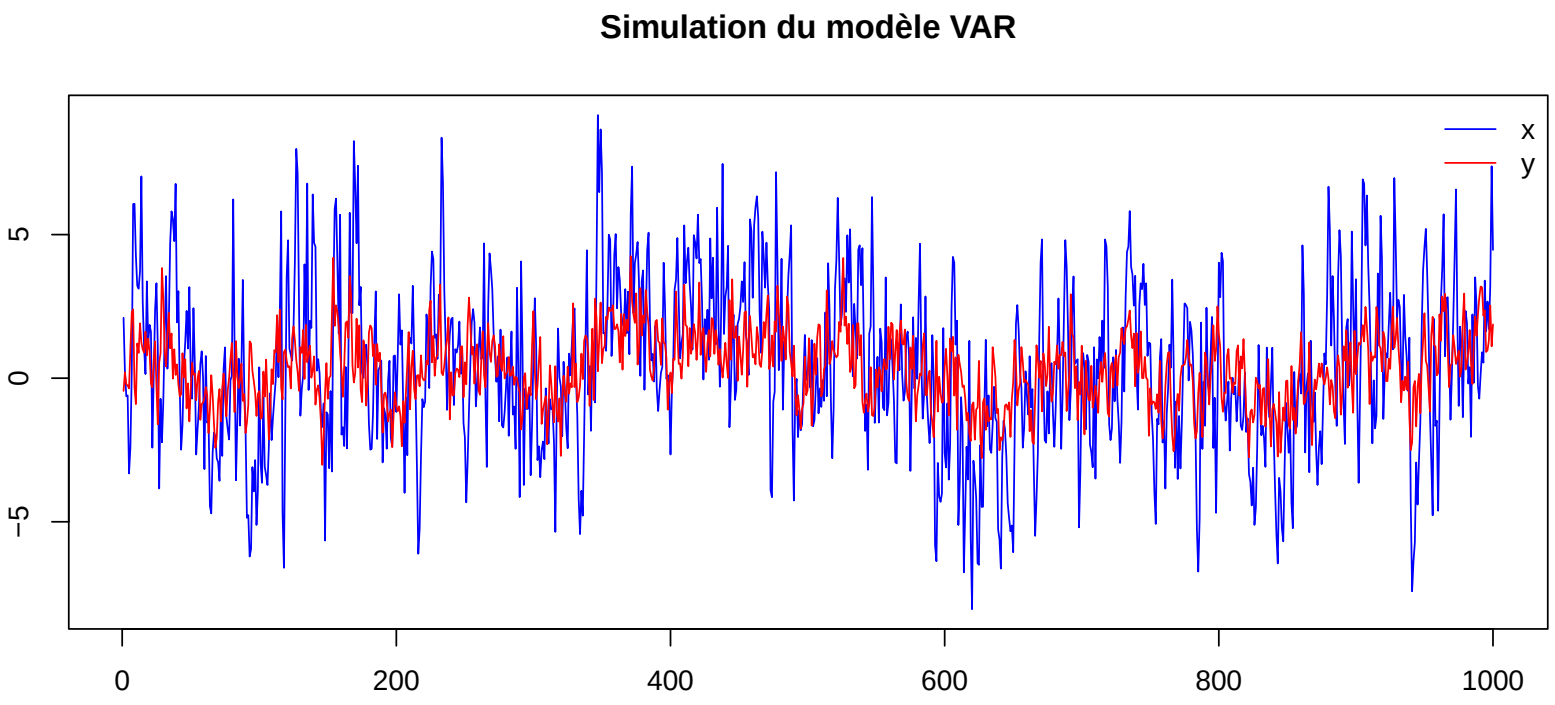

ACF et CCFS

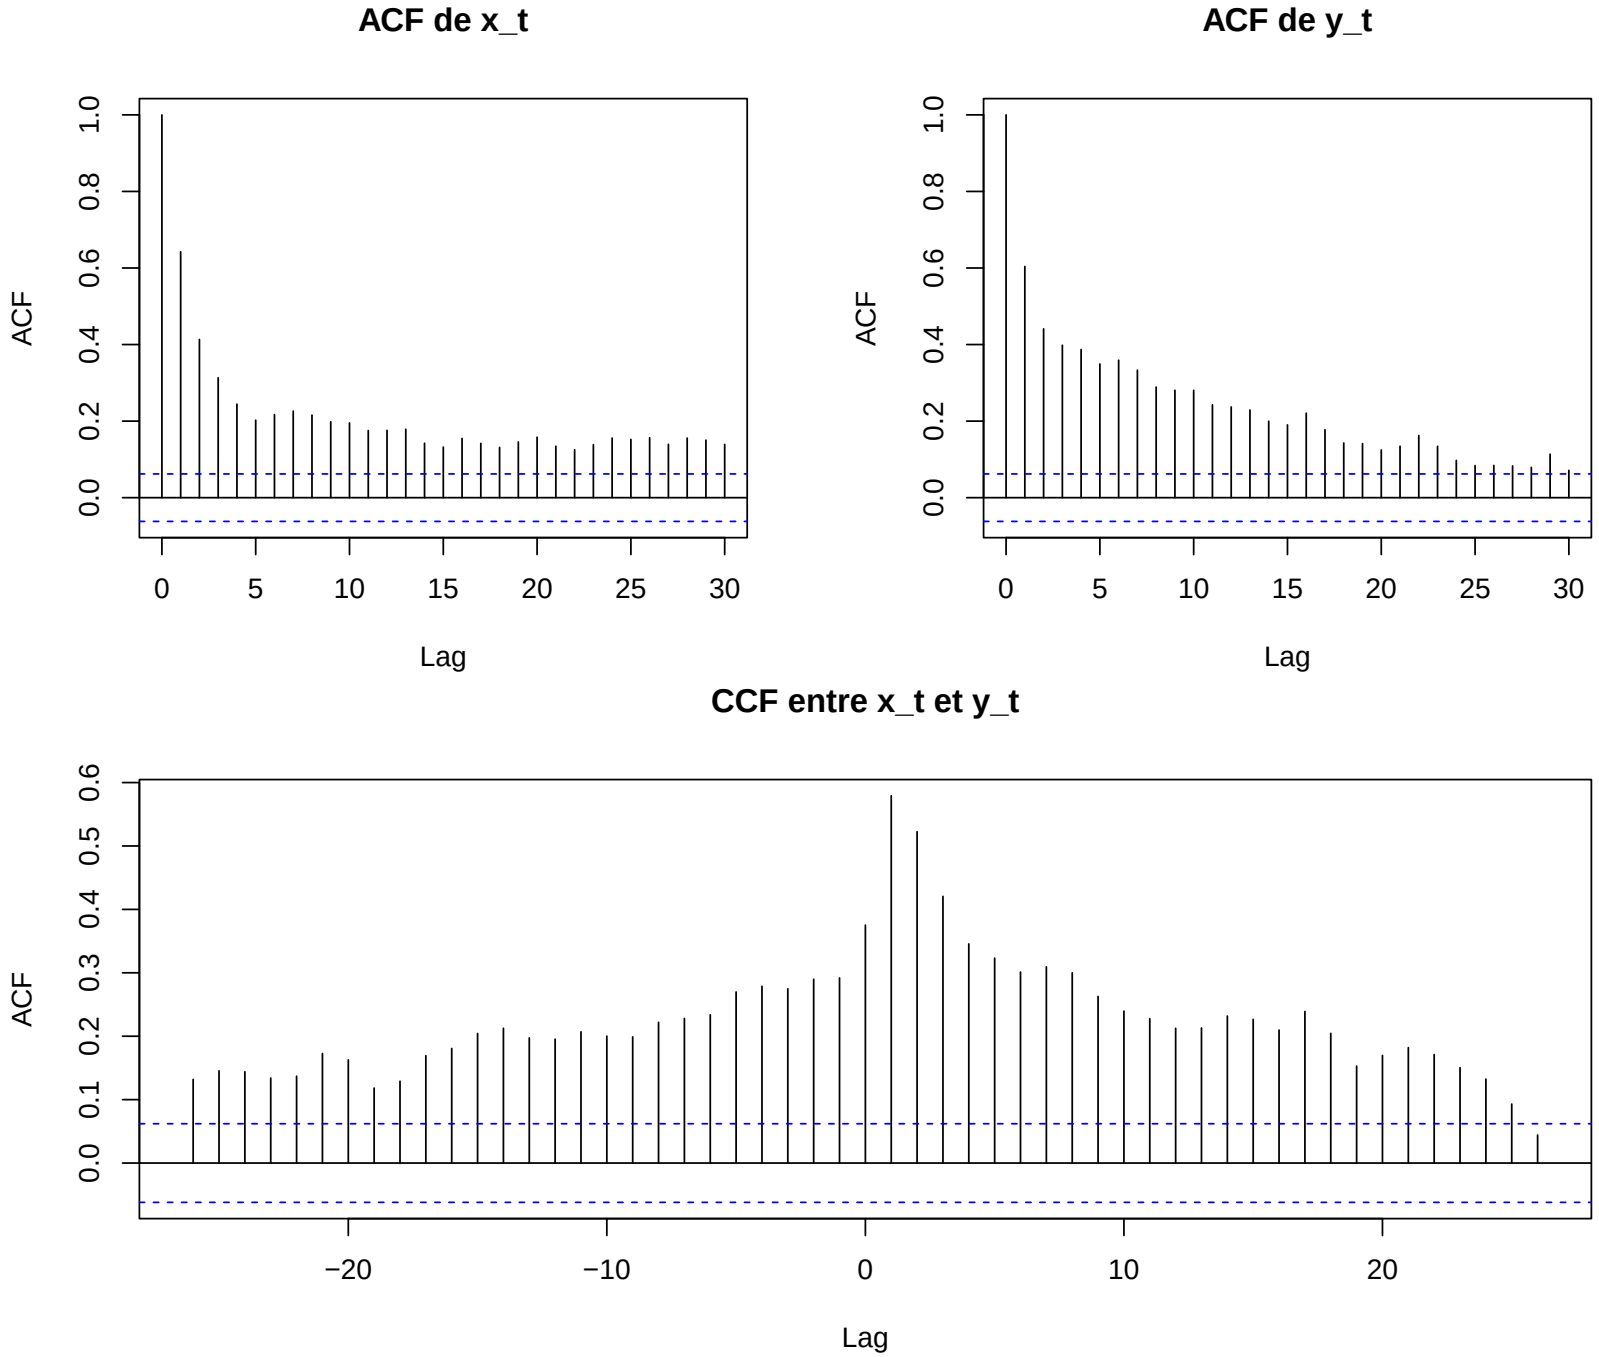

Fonctions PACF

PACF

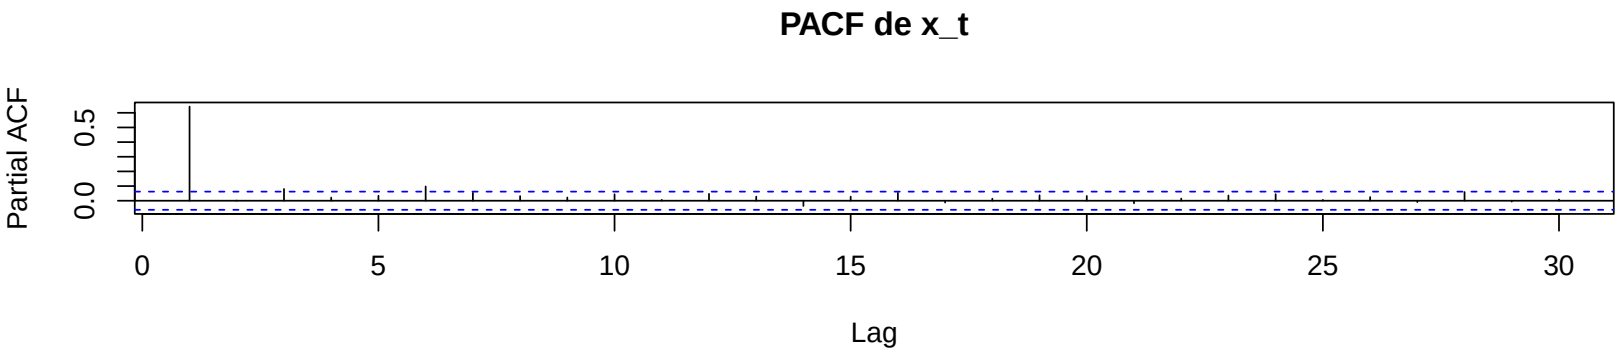

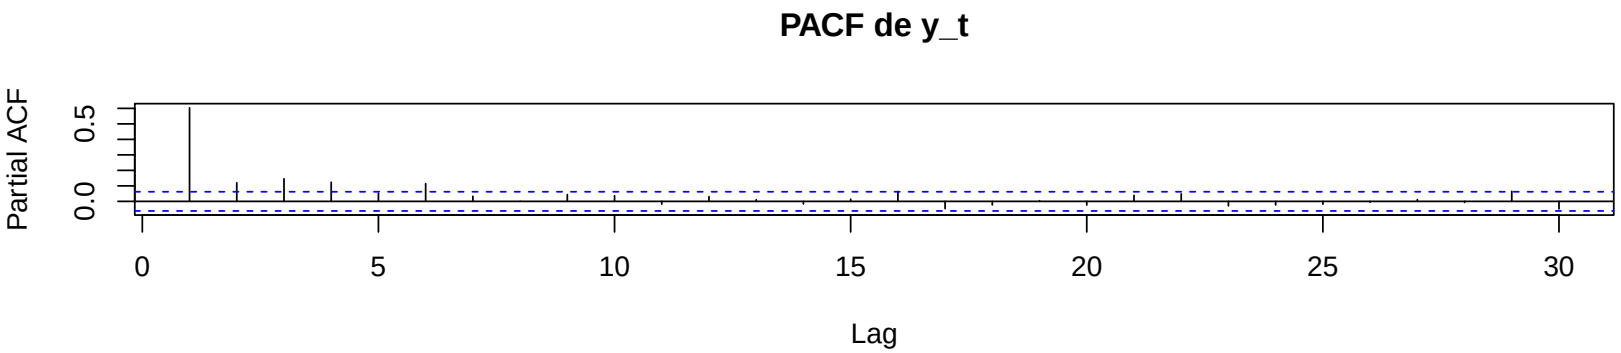

Sélection de modèle

- Choisir la longueur de décalage maximale
- Critères d'information

$$\begin{array}{ll} \text{AIC:} & \ln|\mathbf{\Sigma}(P)| + k^2 P \frac{2}{T} \\ \text{Hannan-Quinn IC (HQIC):} & \ln|\mathbf{\Sigma}(P)| + k^2 P \frac{2 \ln \ln T}{T} \\ \text{BIC:} & \ln|\mathbf{\Sigma}(P)| + k^2 P \frac{\ln T}{T} \end{array}$$

  - $\Sigma(P)$ est la covariance des résidus en utilisant P décalages
  - $|\cdot|$ est le déterminant
- Rapport de vraisemblance

$$\left(T - P_2 k^2\right)\left(\ln|\mathbf{\Sigma}(P_1)| - \ln|\mathbf{\Sigma}(P_2)|\right) \overset{A}{\sim} \chi^2_{(P_2 - P_1)k^2}$$

- Basé sur l'hypothèse de test
  - Général à Spécifique
  - Spécifique à Général

Sélection de la longueur de décalage dans le VAR de la Politique Monétaire

- Décalage maximal : 12 (1 an)

Longueur de décalage	AIC	HQIC	BIC	LR	P-val
0	4.014	3.762	3.605	925	0.000
1	0.279	0.079	$0.000^{\nabla\Delta}$	39.6	0.000
2	0.190	0.042	0.041	40.9	0.000
3	0.096	0.000^{∇}	0.076	29.0	0.001
4	0.050^{∇}	0.007	0.160	7.34	0.602^{∇}
5	0.094	0.103	0.333	29.5	0.001
6	0.047	0.108	0.415	13.2	0.155
7	0.067	0.180	0.564	32.4	0.000
8	0.007	0.172^{Δ}	0.634	19.8	0.019
9	0.000^{Δ}	0.217	0.756	7.68	0.566^{Δ}
10	0.042	0.312	0.928	13.5	0.141
11	0.061	0.382	1.076	13.5	0.141
12	0.079	0.453	1.224	-	-

Causalité de Granger

- Premier concept fondamentalement nouveau
- Examine si les décalages d'une variable sont utiles pour prédire une autre

Définition (Causalité de Granger)

Une variable aléatoire scalaire $\{x_t\}$ est dite **ne pas** causer au sens de Granger $\{y_t\}$ si $\mathrm{E}\left[y_t \mid x_{t-1}, y_{t-1}, x_{t-2}, y_{t-2}, \ldots\right] = \mathrm{E}\left[y_t \mid y_{t-1}, y_{t-2}, \ldots\right]$. C'est-à-dire, $\{x_t\}$ ne cause pas au sens de Granger si la prévision de y_t est la même que l'on conditionne ou non sur les valeurs passées de x_t.

Causalité de Granger

- Se traduit directement en une restriction dans un VAR
- Non restreint

$$\begin{bmatrix} x_t \\ y_t \end{bmatrix} = \begin{bmatrix} \phi_{01} \\ \phi_{02} \end{bmatrix} + \begin{bmatrix} \phi_{11} & \phi_{12} \\ \phi_{21} & \phi_{22} \end{bmatrix} \begin{bmatrix} x_{t-1} \\ y_{t-1} \end{bmatrix} + \begin{bmatrix} \varepsilon_{1,t} \\ \varepsilon_{2,t} \end{bmatrix}$$

- Restreint de sorte que x_t ne GC pas y_t

$$\begin{bmatrix} x_t \\ y_t \end{bmatrix} = \begin{bmatrix} \phi_{01} \\ \phi_{02} \end{bmatrix} + \begin{bmatrix} \phi_{11} & \phi_{12} \\ 0 & \phi_{22} \end{bmatrix} \begin{bmatrix} x_{t-1} \\ y_{t-1} \end{bmatrix} + \begin{bmatrix} \varepsilon_{1,t} \\ \varepsilon_{2,t} \end{bmatrix}$$

$$x_t = \phi_{01} + \phi_{11} x_{t-1} + \phi_{12} y_{t-1} + \varepsilon_{1,t}$$

$$y_t = \phi_{02} + \phi_{22} y_{t-1} + \varepsilon_{2,t} \Leftarrow \text{ Pas de } x_t!$$

Plus de causalité de Granger

- Dans le modèle avec P retards

$$\mathbf{y}_t = \mathbf{\Phi}_0 + \mathbf{\Phi}_1 \mathbf{y}_{t-1} + \mathbf{\Phi}_2 \mathbf{y}_{t-2} + \ldots + \mathbf{\Phi}_P \mathbf{y}_{t-P} + \varepsilon_t$$

- Hypothèse nulle est

$$H_0 : \phi_{ij,1} = \phi_{ij,2} = \ldots = \phi_{ij,P} = 0$$

- Alternative est

$$H_0 : \phi_{ij,1} \neq 0 \text{ ou } \phi_{ij,2} \neq 0 \text{ ou } \ldots \text{ ou } \phi_{ij,P} \neq 0$$

- Test du rapport de vraisemblance

$$\left(T - Pk^2\right) \left(\ln |\mathbf{\Sigma}_r| - \ln |\mathbf{\Sigma}_u|\right) \overset{A}{\sim} \chi^2_P$$

- Σ_u est la covariance des erreurs à partir du modèle non restreint
- Σ_r est la covariance des erreurs à partir du modèle restreint
- $T - Pk^2$ est le nombre d'observations moins le nombre de paramètres libres dans le modèle non restreint

VAR de Politique Monétaire – Campbell

Outil standard dans l'analyse de la politique monétaire

- Taux de chômage (différencié)
- Taux des fonds fédéraux
- Taux d'inflation (différencié)

$$\begin{bmatrix} \Delta\mathrm{UNEMP}_t \\ \mathrm{FF}_t \\ \Delta\mathrm{INF}_t \end{bmatrix} = \Phi_0 + \Phi_1 \begin{bmatrix} \Delta\mathrm{UNEMP}_{t-1} \\ \mathrm{FF}_{t-1} \\ \Delta\mathrm{INF}_{t-1} \end{bmatrix} + \begin{bmatrix} \varepsilon_{1,t} \\ \varepsilon_{2,t} \\ \varepsilon_{3,t} \end{bmatrix}$$

Causalité de Granger dans le VAR de Campbell

- Utiliser le modèle avec 3 décalages (HQIC)
- $H_0 : \phi_{ij,1} = \phi_{ij,2} = \phi_{ij,3} = 0$
- $H_1 : \phi_{ij,1} \neq 0$ ou $\phi_{ij,2} \neq 0$ ou $\phi_{ij,3} \neq 0$
- i représente la série affectée par les décalages de la série j

	Taux des fonds fédéraux		Inflation		Chômage	
Exclusion	P-val	Stat	P-val	Stat	P-val	Stat
Taux des fonds fédéraux	-	-	0.001	13.068	0.014	8.560
Inflation	0.001	14.756	-	-	0.375	1.963
Chômage	0.000	19.586	0.775	0.509	-	-
Tous	0.000	33.139	0.000	18.630	0.005	10.472

Fonctions de réponse impulsionnelle

- Deuxième concept fondamentalement nouveau
- La dynamique complexe d'un VAR rend l'interprétation directe des coefficients difficile
- La solution est d'examiner les réponses impulsionnelles
- La fonction de réponse impulsionnelle de y_i par rapport à un choc dans ε_j, pour tout j et i, est définie comme le changement dans $y_{it+s}, s \geq 0$ pour un choc unitaire dans ε_{jt}
  - Difficile à déchiffrer
- Tant que $\mathbf{y}_t$ est stationnaire en covariance, il doit avoir une représentation VMA,

$$\mathbf{y}_t = \boldsymbol{\mu} + \varepsilon_t + \boldsymbol{\Xi}_1 \varepsilon_{t-1} + \boldsymbol{\Xi}_2 \varepsilon_{t-2} + \dots$$

- $\boldsymbol{\Xi}_j$ sont les réponses impulsionnelles !
- Pourquoi ?
  - Mesurent directement l'effet dans la période j de tout choc

AP(P) et MA(∞)

- Tout AR(P) stationnaire

$$y_t = \phi_0 + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \ldots + \phi_P y_{t-P} + \varepsilon_t$$

peut être représenté comme un MA(∞)

$$y_t = \phi_0 / (1 - \phi_1 - \phi_2 - \ldots - \phi_P) + \varepsilon_t + \sum_{i=1}^{\infty} \phi_i \varepsilon_{t-i}$$

- AR(1)

$$y_t = \phi_0 + \phi_1 y_{t-1} + \varepsilon_t$$

devient

$$y_t = \phi_0 / (1 - \phi_1) + \varepsilon_t + \sum_{i=1}^{\infty} \phi_1^i \varepsilon_{t-i}$$

- Les VAR(P) stationnaires ont la même relation avec VMA(∞)

$$\mathbf{y}_t = \mathbf{\Phi}_0 + \mathbf{\Phi}_1 \mathbf{y}_{t-1} + \mathbf{\Phi}_2 \mathbf{y}_{t-2} + \ldots + \mathbf{\Phi}_P \mathbf{y}_{t-P} + \varepsilon_t$$

$$\mathbf{y}_t = \boldsymbol{\mu} + \varepsilon_t + \mathbf{\Xi}_1 \varepsilon_{t-1} + \mathbf{\Xi}_2 \varepsilon_{t-2} + \ldots$$

Résolution IR

- Facile dans VAR(1)

$$y_t = (\mathbf{I}_K - \Phi_1)^{-1} \Phi_0 + \varepsilon_t + \Phi_1 \varepsilon_{t-1} + \Phi_1^2 \varepsilon_{t-2} + \dots$$

- $\Xi_j = \Phi_1^j$
- Dans le VAR(P) général,

$$\Xi_j = \Phi_1 \Xi_{j-1} + \Phi_2 \Xi_{j-2} + \dots + \Phi_P \Xi_{j-P}$$

où $\Xi_0 = \mathbf{I}_k$ et $\Xi_m = 0$ pour $m < 0$.

- Dans un VAR(2),

$$y_t = \Phi_1 y_{t-1} + \Phi_2 y_{t-2} + \varepsilon_t$$

$$-\Xi_0 = \mathbf{I}_k, \Xi_1 = \Phi_1, \Xi_2 = \Phi_1^2 + \Phi_2, \text{ et } \Xi_3 = \Phi_1^3 + \Phi_1 \Phi_2 + \Phi_2 \Phi_1$$

- Les intervalles de confiance sont également assez compliqués

Considérations pour les chocs

- VAR bivariée simple d'ordre 1

$$\begin{bmatrix} x_t \\ y_t \end{bmatrix} = \begin{bmatrix} \phi_{01} \\ \phi_{02} \end{bmatrix} + \begin{bmatrix} \phi_{11} & \phi_{12} \\ \phi_{21} & \phi_{22} \end{bmatrix} \begin{bmatrix} x_{t-1} \\ y_{t-1} \end{bmatrix} + \begin{bmatrix} \varepsilon_{1,t} \\ \varepsilon_{2,t} \end{bmatrix}$$

- La manière dont vous choquez importe
- Dépend de la corrélation entre $\varepsilon_{1,t}$ et $\varepsilon_{2,t}$
- 3 méthodes
  - Ignorer la corrélation et choquer simplement $\varepsilon_{j,t}$ avec un choc d'écart-type unitaire
  - Utiliser Cholesky pour factoriser Σ et utiliser $\Sigma^{1/2}\mathbf{e}_j$ où $\mathbf{e}_j$ est un vecteur de zéros avec 1 dans la $j^{\text{ème}}$ position

$$\mathbf{\Sigma} = \begin{bmatrix} 1 & .5 \\ .5 & 1 \end{bmatrix} \quad \mathbf{\Sigma}_C^{1/2} = \begin{bmatrix} 1 & 0 \\ .5 & .866 \end{bmatrix}$$

    - L'ordre des variables importe
  - "Réponse impulsionnelle généralisée" qui utilise une méthode de projection

Exemple des différents chocs

- Définir la covariance des erreurs

$$\mathbf{\Sigma} = \begin{bmatrix} \sigma_x^2 & \sigma_x \sigma_y \rho \\ \sigma_x \sigma_y \rho & \sigma_y^2 \end{bmatrix}$$

- Standardisé

$$\begin{bmatrix} \sigma_x \\ 0 \end{bmatrix} \text{ et } \begin{bmatrix} 0 \\ \sigma_y \end{bmatrix}$$

- Cholesky

$$\mathbf{\Sigma}_C^{1/2} \begin{bmatrix} 0 \\ 1 \end{bmatrix} = \begin{bmatrix} \sigma_x & 0 \\ \sigma_y \rho & \sigma_y \sqrt{1-\rho^2} \end{bmatrix} \begin{bmatrix} 0 \\ 1 \end{bmatrix} = \begin{bmatrix} 0 \\ \sigma_y \sqrt{1-\rho^2} \end{bmatrix}$$

$$\begin{bmatrix} \sigma_x & 0 \\ \sigma_y \rho & \sigma_y \sqrt{1-\rho^2} \end{bmatrix} \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} \sigma_x \\ \sigma_y \rho \end{bmatrix}, \text{ autre est } \begin{bmatrix} 0 \\ \sigma_y \sqrt{1-\rho^2} \end{bmatrix}$$

Réponses impulsionnelles

- Taux des fonds fédéraux ordonné en premier
- Réponse à un choc des fonds fédéraux
- Factorisation de Cholesky

```
irf_var_FF_INF <- irf(PolMon, impulse = "DFF.d", response = "GDPDEF.dd")
irf_var_FF_UNRATE <- irf(PolMon, impulse = "DFF.d", response = "UNRATE.d")
irf_var_FF_FF <- irf(PolMon, impulse = "DFF.d", response = "DFF.d")
par(mfrow=c(1,3))
plot(irf_var_FF_INF)
plot(irf_var_FF_UNRATE)
plot(irf_var_FF_FF)
par(mfrow=c(1,1))
```

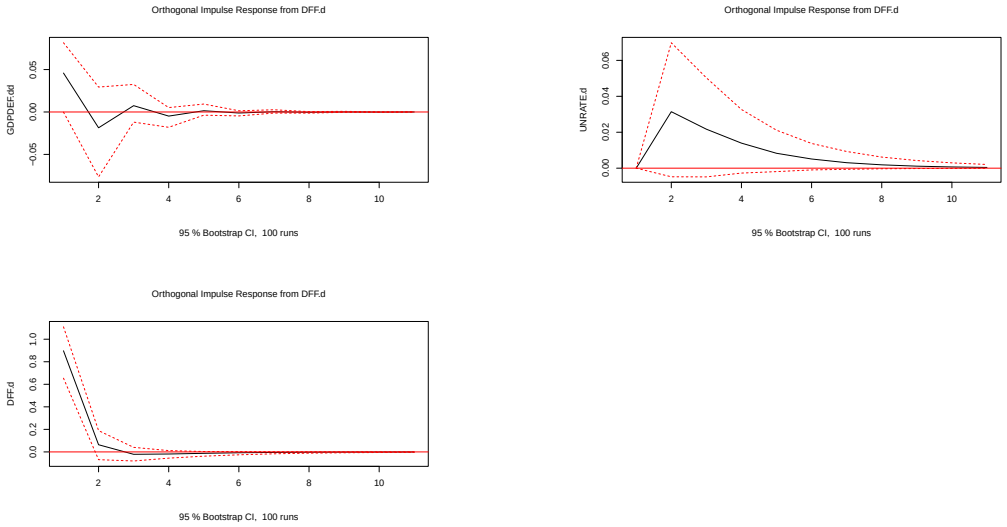

Cointégration

- La cointégration est la version VAR des racines unitaires
- Établit des relations à long terme entre deux variables à racine unitaire
  - La consommation a une racine unitaire, le revenu a une racine unitaire
  - Consommation - Revenu : ????

Définition (Intégré d'Ordre 1)

Une variable y_t est intégrée d'ordre 1, ou I(1), si y_t est non stationnaire et $\Delta y_t = y_t - y_{t-1}$ est stationnaire.

Cointégration

Définition (Cointégration Bivariée)

x_t et y_t sont cointégrés si les deux sont I(1), et il existe un vecteur β avec les deux éléments non nuls tels que

$$\beta_1 x_t - \beta_2 y_t \sim I(0)$$

- Lien fort entre x_t et y_t
- Les deux sont des marches aléatoires mais la différence retourne à la moyenne
- Retour moyen à la tendance (tendance stochastique)

À quoi ressemble la cointégration ?

$$\mathbf{y}_t = \mathbf{\Phi}_{ij}\mathbf{y}_{t-1} + \varepsilon_t$$

$$\mathbf{\Phi}_{11} = \begin{bmatrix} 0.8 & 0.2 \\ 0.2 & 0.8 \end{bmatrix}, \quad \lambda_i = 1, 0.6$$

$$\mathbf{\Phi}_{21} = \begin{bmatrix} 0.7 & 0.2 \\ 0.2 & 0.7 \end{bmatrix}, \quad \lambda_i = 0.9, 0.5$$

$$\mathbf{\Phi}_{12} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, \quad \lambda_i = 1, 1$$

$$\mathbf{\Phi}_{22} = \begin{bmatrix} -0.3 & 0.3 \\ 0.1 & -0.2 \end{bmatrix}, \quad \lambda_i = -0.43, -0.06$$

Persistance, Anti-persistance et Cointégration

```
## [1] 1.0 0.6
```

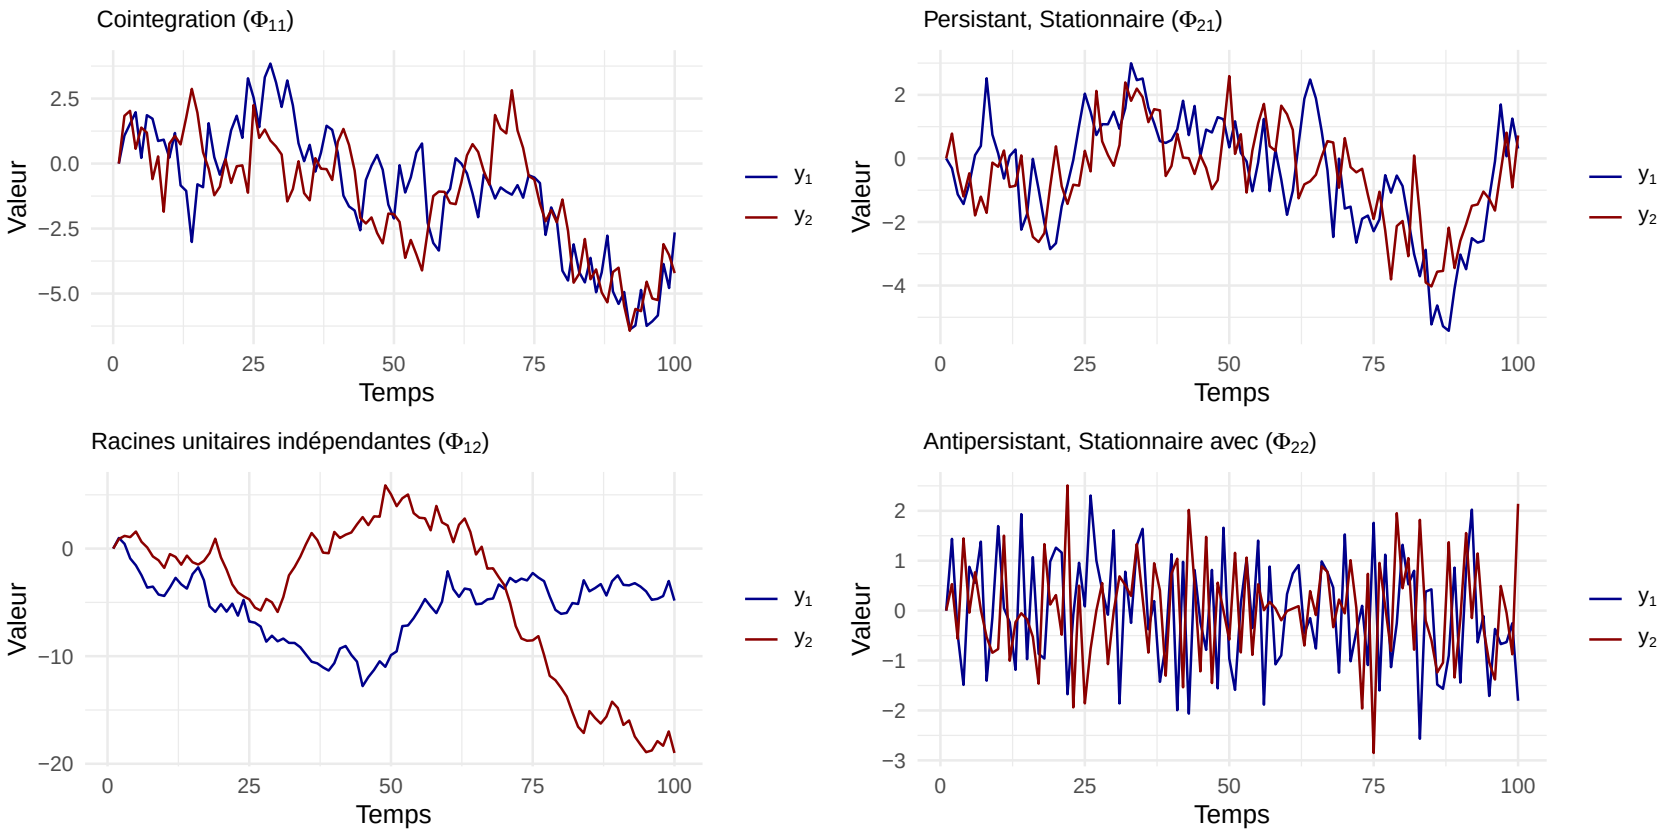

Comment savons-nous quand un VAR est cointégré ?

- La condition des valeurs propres détermine si un VAR(1) est cointégré

$$\begin{bmatrix} y_t \\ x_t \end{bmatrix} = \begin{bmatrix} .8 & .2 \\ .2 & .8 \end{bmatrix} \begin{bmatrix} y_{t-1} \\ x_{t-1} \end{bmatrix} + \begin{bmatrix} \varepsilon_{1,t} \\ \varepsilon_{2,t} \end{bmatrix}$$

- Cointégré si une seule valeur propre est unitaire.
- Si tous inférieurs à 1 : ??
- Si les deux 1 : deux racines unitaires indépendantes

$$\mathbf{\Phi}_{11} = \begin{bmatrix} .8 & .2 \\ .2 & .8 \end{bmatrix} \quad \mathbf{\Phi}_{12} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

$\lambda_i = 1, 0.6$ $\qquad$ $\lambda_i = 1, 1$

$$\mathbf{\Phi}_{21} = \begin{bmatrix} .7 & .2 \\ .2 & .7 \end{bmatrix} \quad \mathbf{\Phi}_{22} = \begin{bmatrix} -.3 & .3 \\ .1 & -.2 \end{bmatrix}$$

$\lambda_i = 0.9, 0.5$ $\qquad$ $\lambda_i = -0.43, -0.06$

Modèles de Correction d'Erreur

- Point majeur de la cointégration
  - Cointégré $\Leftrightarrow$ Modèle de correction d'erreur
- Qu'est-ce qu'un modèle de correction d'erreur ?
  - VAR cointégré :

$$\begin{bmatrix} y_t \\ x_t \end{bmatrix} = \begin{bmatrix} .8 & .2 \\ .2 & .8 \end{bmatrix} \begin{bmatrix} y_{t-1} \\ x_{t-1} \end{bmatrix} + \begin{bmatrix} \varepsilon_{1,t} \\ \varepsilon_{2,t} \end{bmatrix}$$

  - Modèle de correction d'erreur :

$$\begin{bmatrix} \Delta y_t \\ \Delta x_t \end{bmatrix} = \begin{bmatrix} -.2 & .2 \\ .2 & -.2 \end{bmatrix} \begin{bmatrix} y_{t-1} \\ x_{t-1} \end{bmatrix} + \begin{bmatrix} \varepsilon_{1,t} \\ \varepsilon_{2,t} \end{bmatrix}$$

  - Forme normalisée

$$\begin{bmatrix} \Delta y_t \\ \Delta x_t \end{bmatrix} = \begin{bmatrix} -.2 \\ .2 \end{bmatrix} \begin{bmatrix} 1 & -1 \end{bmatrix} \begin{bmatrix} y_{t-1} \\ x_{t-1} \end{bmatrix} + \begin{bmatrix} \varepsilon_{1,t} \\ \varepsilon_{2,t} \end{bmatrix}$$

- $[1 \quad -1]$ est le vecteur de cointégration
- $[-.2 \quad .2]'$ mesure la vitesse d'ajustement

De VAR à VECM

$$\begin{bmatrix} y_t \\ x_t \end{bmatrix} = \begin{bmatrix} .8 & .2 \\ .2 & .8 \end{bmatrix} \begin{bmatrix} y_{t-1} \\ x_{t-1} \end{bmatrix} + \begin{bmatrix} \varepsilon_{1,t} \\ \varepsilon_{2,t} \end{bmatrix}$$

Soustraire $[y_{t-1} x_{t-1}]'$ des deux côtés

$$\begin{bmatrix} y_t \\ x_t \end{bmatrix} - \begin{bmatrix} y_{t-1} \\ x_{t-1} \end{bmatrix} = \begin{bmatrix} .8 & .2 \\ .2 & .8 \end{bmatrix} \begin{bmatrix} y_{t-1} \\ x_{t-1} \end{bmatrix} - \begin{bmatrix} y_{t-1} \\ x_{t-1} \end{bmatrix} + \begin{bmatrix} \varepsilon_{1,t} \\ \varepsilon_{2,t} \end{bmatrix}$$

$$\begin{bmatrix} \Delta y_t \\ \Delta x_t \end{bmatrix} = \left(\begin{bmatrix} .8 & .2 \\ .2 & .8 \end{bmatrix} - \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \right) \begin{bmatrix} y_{t-1} \\ x_{t-1} \end{bmatrix} + \begin{bmatrix} \varepsilon_{1,t} \\ \varepsilon_{2,t} \end{bmatrix}$$

$$\begin{bmatrix} \Delta y_t \\ \Delta x_t \end{bmatrix} = \begin{bmatrix} -.2 & .2 \\ .2 & -.2 \end{bmatrix} \begin{bmatrix} y_{t-1} \\ x_{t-1} \end{bmatrix} + \begin{bmatrix} \varepsilon_{1,t} \\ \varepsilon_{2,t} \end{bmatrix}$$

$$\begin{bmatrix} \Delta y_t \\ \Delta x_t \end{bmatrix} = \begin{bmatrix} -.2 \\ .2 \end{bmatrix} \begin{bmatrix} 1 & -1 \end{bmatrix} \begin{bmatrix} y_{t-1} \\ x_{t-1} \end{bmatrix} + \begin{bmatrix} \varepsilon_{1,t} \\ \varepsilon_{2,t} \end{bmatrix}$$

Vecteurs de cointégration

- La relation de cointégration peut toujours être décomposée

$$\Delta \mathbf{y}_t = \boldsymbol{\pi} \mathbf{y}_{t-1} + \varepsilon_t$$
$$\boldsymbol{\pi} = \boldsymbol{\alpha}\boldsymbol{\beta}'$$

- α mesure la vitesse de convergence
- β contiennent les vecteurs de cointégration
- Le nombre de vecteurs de cointégration est rank $(\boldsymbol{\alpha}\boldsymbol{\beta}')$

$$\boldsymbol{\alpha}\boldsymbol{\beta}' = \begin{bmatrix} 0.3 & 0.2 & -0.36 \\ 0.2 & 0.5 & -0.35 \\ -0.3 & -0.3 & 0.39 \end{bmatrix}$$

Détermination des vecteurs de cointégration

$$\Delta \mathbf{y}_t = \boldsymbol{\pi} \mathbf{y}_{t-1} + \varepsilon_t$$

$$\boldsymbol{\pi} = \begin{bmatrix} 0.3 & 0.2 & -0.36 \\ 0.2 & 0.5 & -0.35 \\ -0.3 & -0.3 & 0.39 \end{bmatrix}$$

- Mettre $\boldsymbol{\pi}$ sous forme échelonnée par ligne

$$\text{Forme Échelonnée par Ligne } = \begin{bmatrix} 1 & 0 & -1 \\ 0 & 1 & -0.3 \\ 0 & 0 & 0 \end{bmatrix}$$

- Rappel $\boldsymbol{\pi} = \boldsymbol{\alpha}\boldsymbol{\beta}'$

$$\boldsymbol{\beta} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ -1 & -.3 \end{bmatrix} \qquad \boldsymbol{\alpha} = \begin{bmatrix} .3 & .2 \\ .2 & .5 \\ -.3 & -.3 \end{bmatrix}$$

Résolution des vecteurs de cointégration

$$\boldsymbol{\alpha}\boldsymbol{\beta}' = \begin{bmatrix} 0.3 & 0.2 & -0.36 \\ 0.2 & 0.5 & -0.35 \\ -0.3 & -0.3 & 0.39 \end{bmatrix}$$

$$\text{Forme Échelonnée par Ligne} \Rightarrow \begin{bmatrix} 1 & 0 & -1 \\ 0 & 1 & -0.3 \\ 0 & 0 & 0 \end{bmatrix}$$

$$\boldsymbol{\beta} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ \beta_1 & \beta_2 \end{bmatrix}$$

et $\boldsymbol{\alpha}$ a 6 paramètres inconnus. $\boldsymbol{\alpha}\boldsymbol{\beta}'$ peut être combiné pour produire

$$\boldsymbol{\pi} = \begin{bmatrix} \alpha_{11} & \alpha_{12} & \alpha_{11}\beta_1 + \alpha_{12}\beta_2 \\ \alpha_{21} & \alpha_{22} & \alpha_{21}\beta_1 + \alpha_{22}\beta_2 \\ \alpha_{31} & \alpha_{32} & \alpha_{31}\beta_1 + \alpha_{32}\beta_2 \end{bmatrix}$$

Tester la cointégration

- Deux tests pour la cointégration
  - Engle-Granger
  - Johansen
- Nous allons nous concentrer sur Engle-Granger
  - Simple et intuitif
  - Seulement applicable avec 1 relation de cointégration
- Tester la propriété clé de la cointégration : la différence est I(0)
- La plupart du travail est une simple OLS

$$y_t = \delta_0 + \beta x_t + \varepsilon_t$$

- Reste du travail est de tester $\hat{\varepsilon}_t$ pour une racine unitaire
- Johansen teste les valeurs propres de $\pi = \alpha\beta'$ directement.

Procédure Engle-Granger

Algorithme (Test Engle-Granger)

1. Commencer par analyser x_t et y_t isolément. Les deux doivent être des racines unitaires pour envisager la cointégration.
2. Estimer la relation à long terme

$$y_t = \delta_0 + \beta x_t + \varepsilon_t$$

   et tester $H_0 : \gamma = 0$ contre $H_1 : \gamma < 0$ dans la régression ADF

$$\Delta\hat{\varepsilon}_t = \gamma\hat{\varepsilon}_{t-1} + \delta_1\Delta\hat{\varepsilon}_{t-1} + \ldots + \delta_p\Delta\hat{\varepsilon}_{t-P} + \eta_t$$

3. En utilisant les paramètres estimés, spécifier et estimer la forme de correction d'erreur de la relation,

$$\begin{bmatrix} \Delta x_t \\ \Delta y_t \end{bmatrix} = \begin{matrix} \pi_{01} \\ \pi_{02} \end{matrix} + \begin{matrix} \alpha_1\hat{\varepsilon}_t \\ \alpha_2\hat{\varepsilon}_t \end{matrix} + \boldsymbol{\pi}_1 \begin{bmatrix} \Delta x_{t-1} \\ \Delta y_{t-1} \end{bmatrix} + \ldots + \boldsymbol{\pi}_P \begin{bmatrix} \Delta x_{t-P} \\ \Delta y_{t-P} \end{bmatrix} + \begin{bmatrix} \eta_{1,t} \\ \eta_{2,t} \end{bmatrix}$$

4. Évaluer le modèle

Considérations Engle-Granger

- Termes déterministes
  - Pas de termes déterministes : seulement dans des circonstances spéciales

$$y_t = \beta x_t + \varepsilon_t$$

  - Constante : cas standard

$$y_t = \delta_0 + \beta x_t + \varepsilon_t$$

  - Constante et tendance temporelle : permettre différents taux de croissance/tendances temporelles dans les variables

$$y_t = \delta_0 + \delta_1 \boldsymbol{t} + \beta x_t + \varepsilon_t$$

Valeurs Critiques

- Les valeurs critiques dépendent des déterministes dans la régression CI
  - Les modèles avec plus de déterministes ont des valeurs critiques plus basses (plus négatives)
- Les valeurs critiques dépendent du nombre de variables I(1) du côté droit
  - Les modèles plus grands ont des valeurs critiques plus basses

Exemple : cay

- La relation consommation-richesse agrégée a été une série cointégrée intéressante dans la littérature financière récente
- A relancé le CCAPM
- Trois composantes :
  - Consommation (c)
  - Richesse en actifs (a)
  - Revenu du travail (richesse humaine) (y)
- Écart par rapport à la relation à long terme lié au rendement attendu
- Relation de cointégration : $c_t + 0.643 - 0.249a_t - 0.785y_t$

Tests de racine unitaire			
Série	T-stat	P-val	Décalages ADF
c	-1.198	0.674	5
a	-0.205	0.938	3
y	-2.302	0.171	0
$\hat{\varepsilon}_t^c$	-2.706	0.383	1
$\hat{\varepsilon}_t^a$	-2.573	0.455	0
$\hat{\varepsilon}_t^y$	-2.679	0.398	1

```
##
##  Augmented Dickey-Fuller Test
##
## data:  donnees$log_c
## Dickey-Fuller = 0.114, Lag order = 6, p-value = 0.99
## alternative hypothesis: stationary

##
##  Augmented Dickey-Fuller Test
##
## data:  donnees$log_a
## Dickey-Fuller = -1.0331, Lag order = 6, p-value = 0.9316
## alternative hypothesis: stationary

##
##  Augmented Dickey-Fuller Test
##
## data:  donnees$log_y
## Dickey-Fuller = 0.14887, Lag order = 6, p-value = 0.99
## alternative hypothesis: stationary
```

```
##
## ######################
## # Johansen-Procedure #
## ######################
##
## Test type: maximal eigenvalue statistic (lambda max) , with linear trend
##
## Eigenvalues (lambda):
## [1] 0.13630870 0.02601146 0.01455762
##
## Values of teststatistic and critical values of test:
##
##           test 10pct  5pct  1pct
## r <= 2 |  3.55  6.50  8.18 11.65
## r <= 1 |  6.38 12.91 14.90 19.19
## r = 0  | 35.46 18.90 21.07 25.75
##
## Eigenvectors, normalised to first column:
## (These are the cointegration relations)
##
##            log_c.l2   log_a.l2   log_y.l2
## log_c.l2  1.0000000  1.0000000  1.0000000
## log_a.l2  0.1314215  0.3990464 -0.2527867
## log_y.l2 -1.1290374 -1.4840821 -0.7514655
##
## Weights W:
## (This is the loading matrix)
##
```

VAR → VECM

```
vecm <- cajorls(jo_test, r=1)
vecm_var <- vec2var(jo_test, r=1)
vecm_residuals <- residuals(vecm_var)
```

Tests de diagnostic – Corrélation sérielle

```r
# 1. Corrélation sérielle test
serial_test_result <- serial.test(vecm_var)
print(serial_test_result)
```

```
##
##  Portmanteau Test (asymptotic)
##
## data:  Residuals of VAR object vecm_var
## Chi-squared = 149.39, df = 129, p-value = 0.1058
```

```
## $serial
##
##  Portmanteau Test (asymptotic)
##
## data:  Residuals of VAR object vecm_var
## Chi-squared = 149.39, df = 129, p-value = 0.1058
```

Tests de diagnostic – ARCH

```r
# 2. ARCH test (FinTS::ArchTest)
arch_test_result <- apply(vecm_residuals, 2, function(x) ArchTest(x, lags = 1))
print(arch_test_result)
```

```
## $`resids of log_c`
##
##  ARCH LM-test; Null hypothesis: no ARCH effects
##
## data:  x
## Chi-squared = 2.4735, df = 1, p-value = 0.1158
##
##
## $`resids of log_a`
##
##  ARCH LM-test; Null hypothesis: no ARCH effects
##
## data:  x
## Chi-squared = 14.594, df = 1, p-value = 0.0001333
##
##
## $`resids of log_y`
##
##  ARCH LM-test; Null hypothesis: no ARCH effects
##
## data:  x
## Chi-squared = 5.3311, df = 1, p-value = 0.02095
```

Tests de diagnostic – Normalité

```r
# 3. Normalité test
normality_test_result <- normality.test(vecm_var)
print(normality_test_result)
```

```
## $JB
##
##  JB-Test (multivariate)
##
## data:  Residuals of VAR object vecm_var
## Chi-squared = 76.833, df = 6, p-value = 1.61e-14
##
##
## $Skewness
##
##  Skewness only (multivariate)
##
## data:  Residuals of VAR object vecm_var
## Chi-squared = 13.903, df = 3, p-value = 0.00304
##
##
## $Kurtosis
##
##  Kurtosis only (multivariate)
##
## data:  Residuals of VAR object vecm_var
## Chi-squared = 62.929, df = 3, p-value = 1.39e-13
```

Graphiques - séries

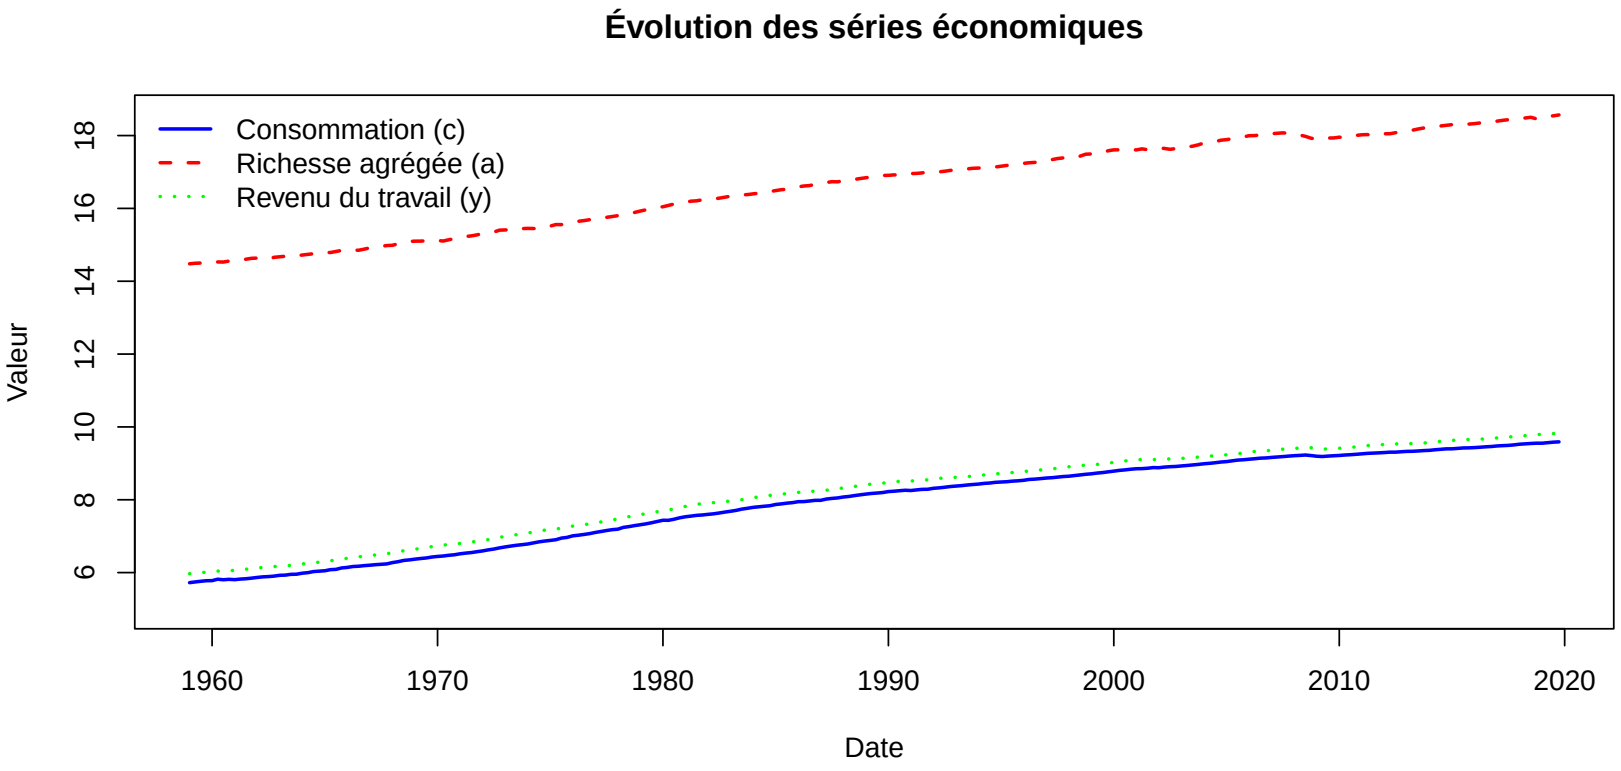

Graphiques - résidus

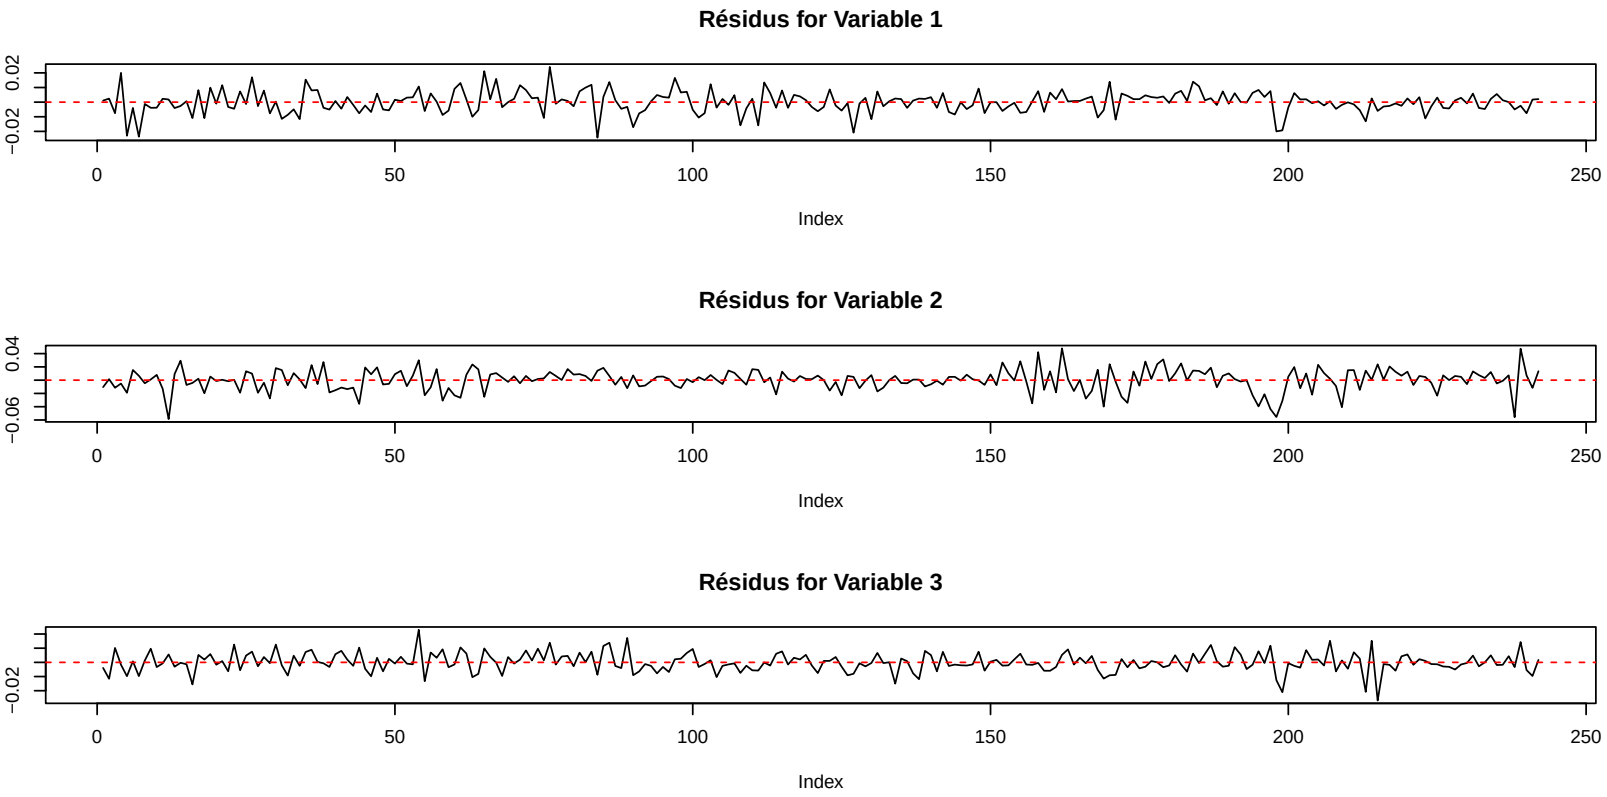

Graphiques - ACF, PACF

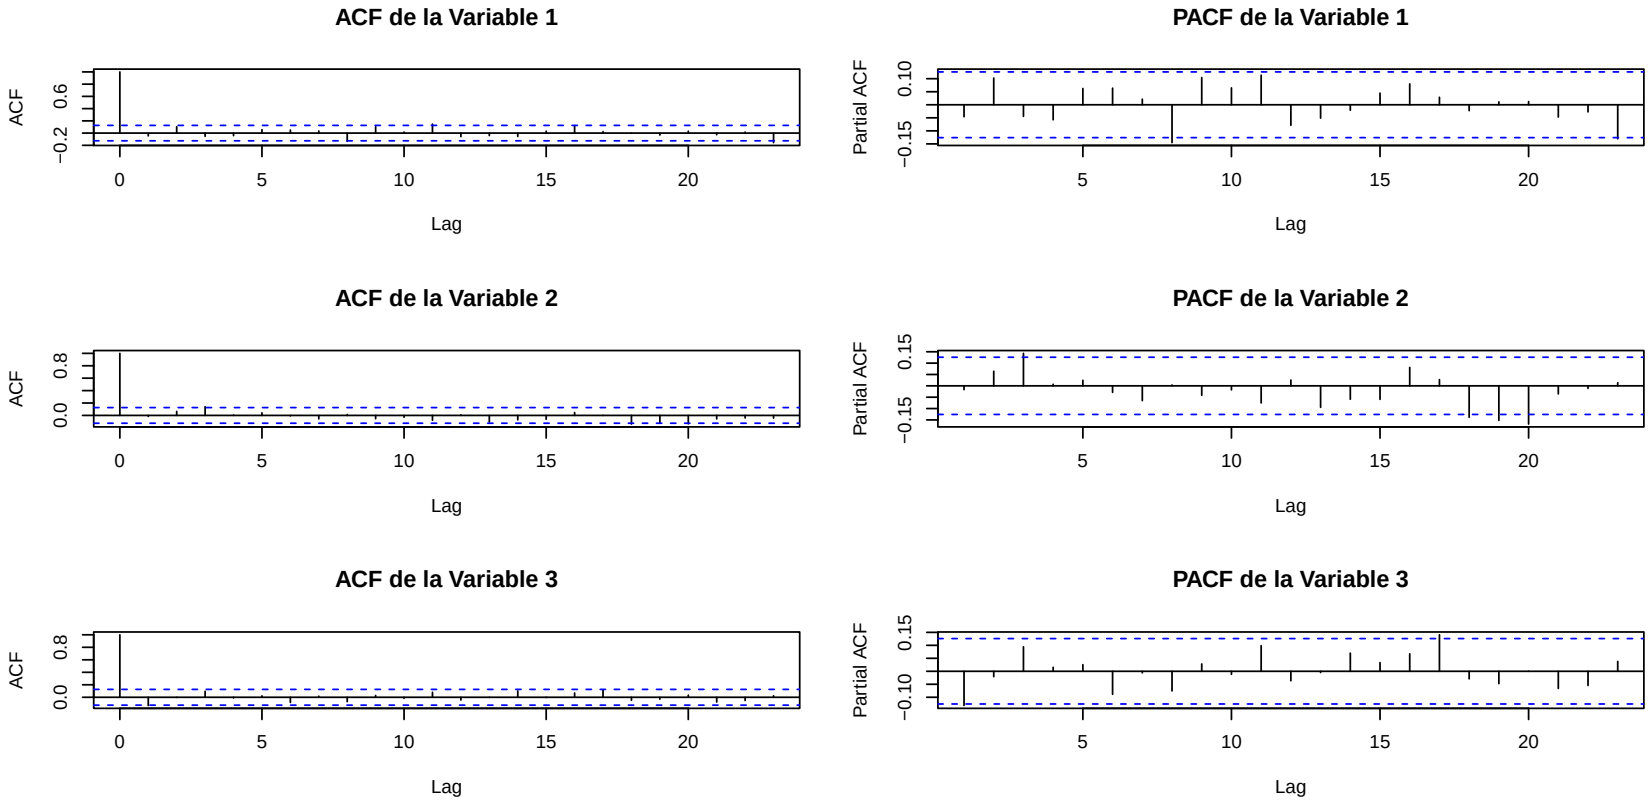

Graphiques - Histogramme et densité

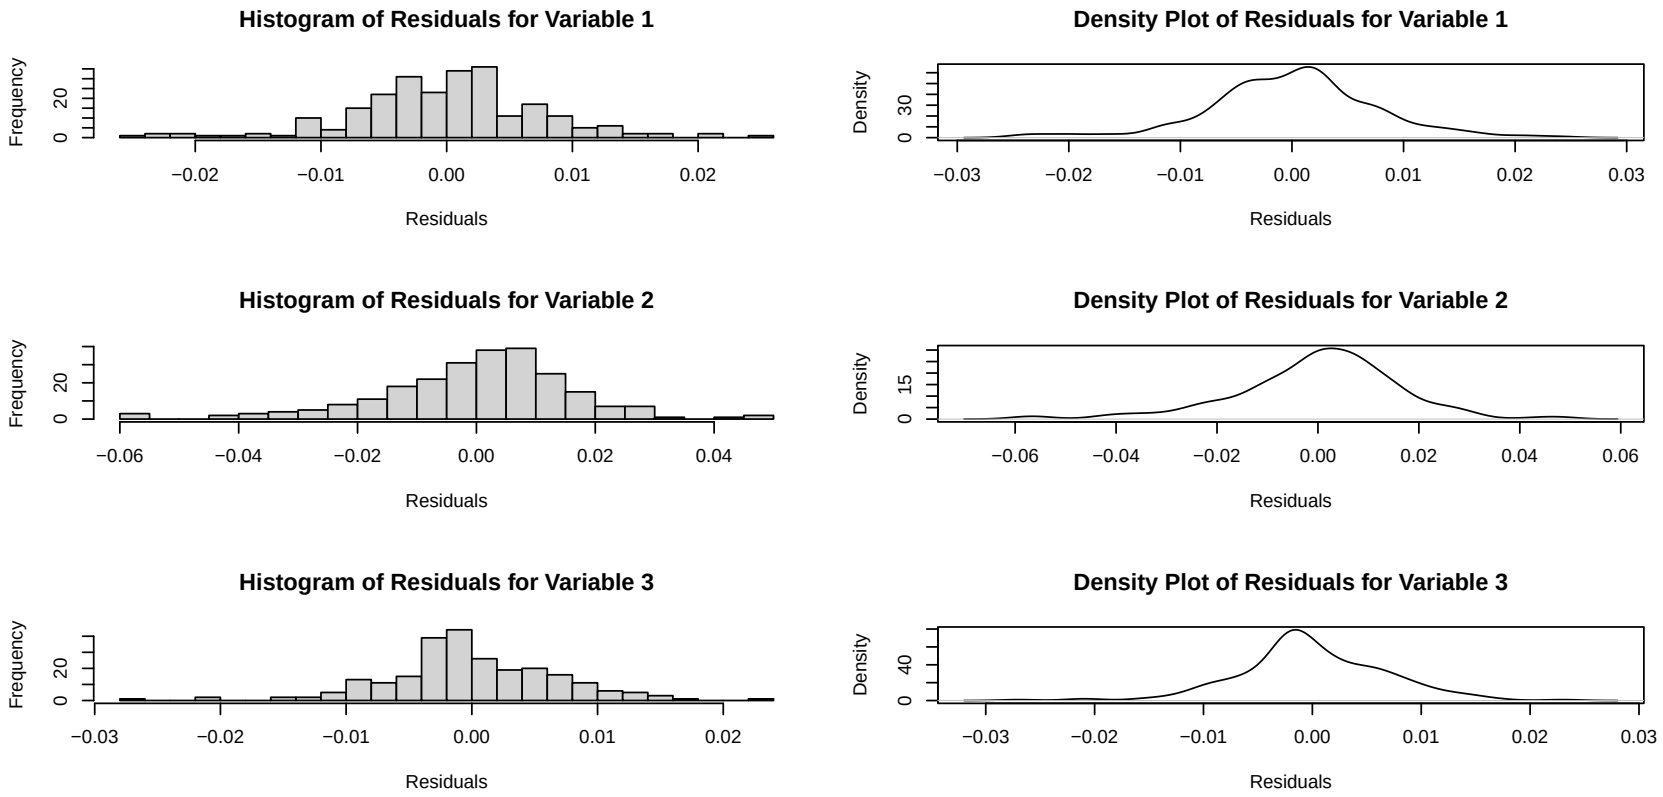

Graphiques - QQplot

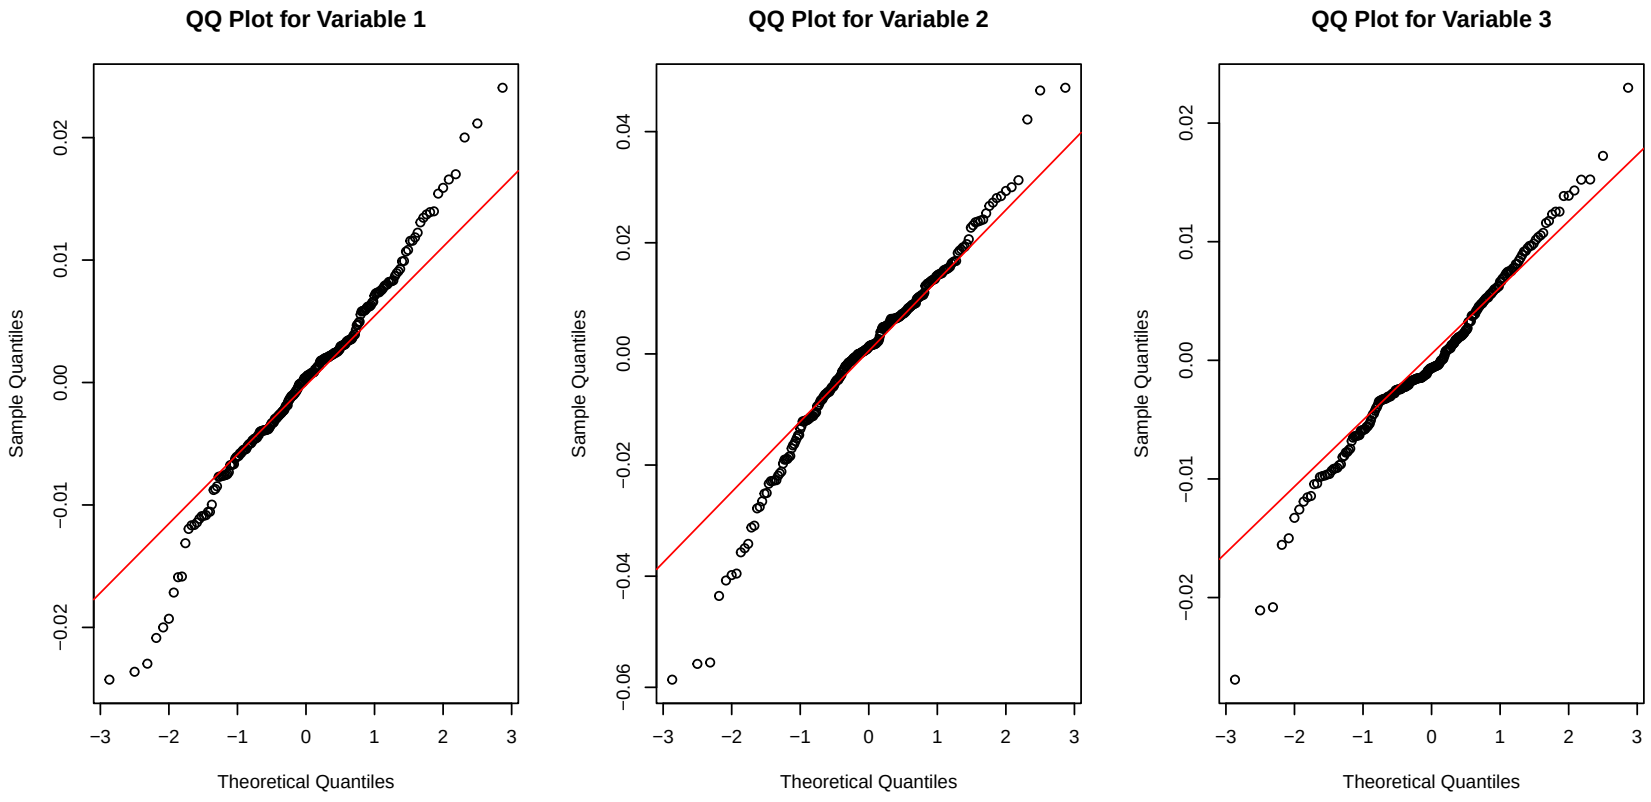

Graphiques - ARCH

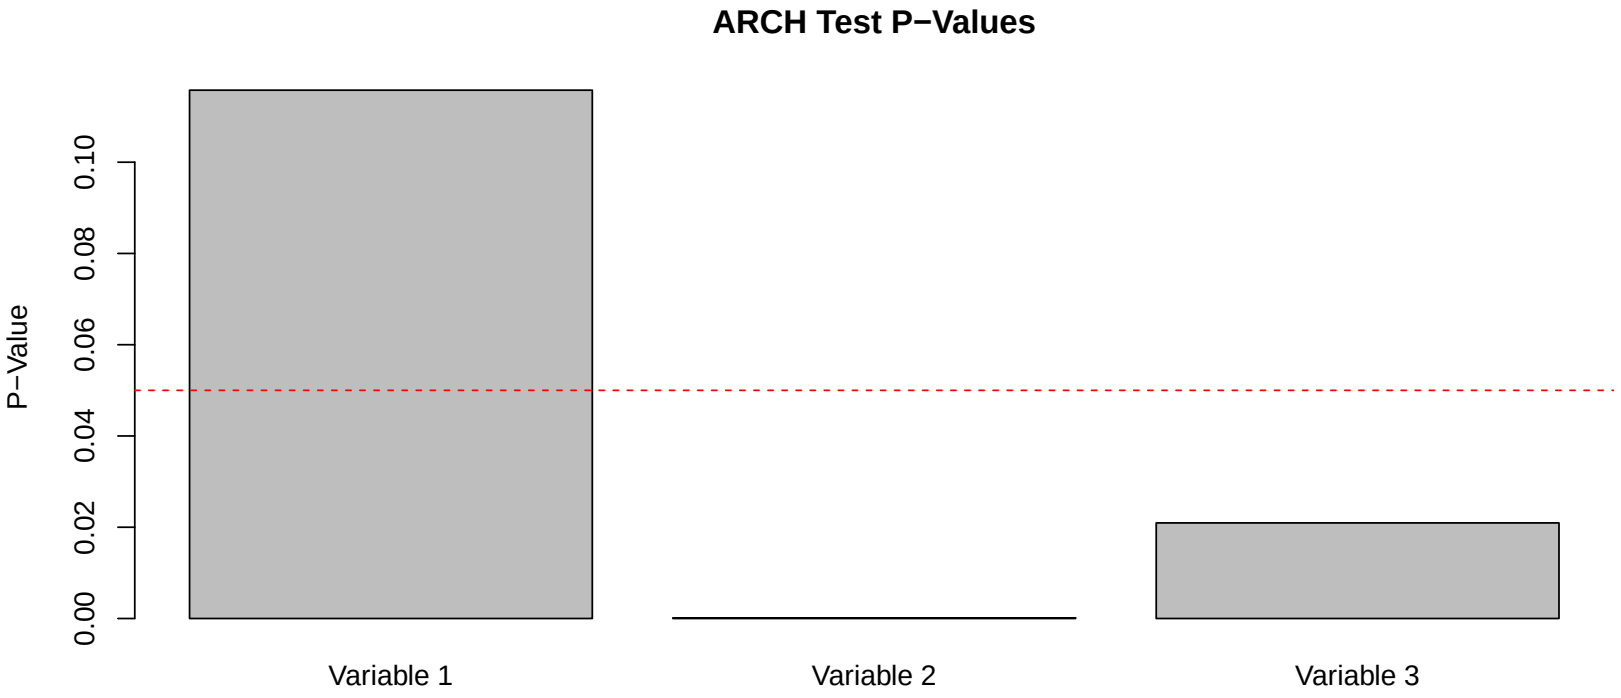

Graphique - global

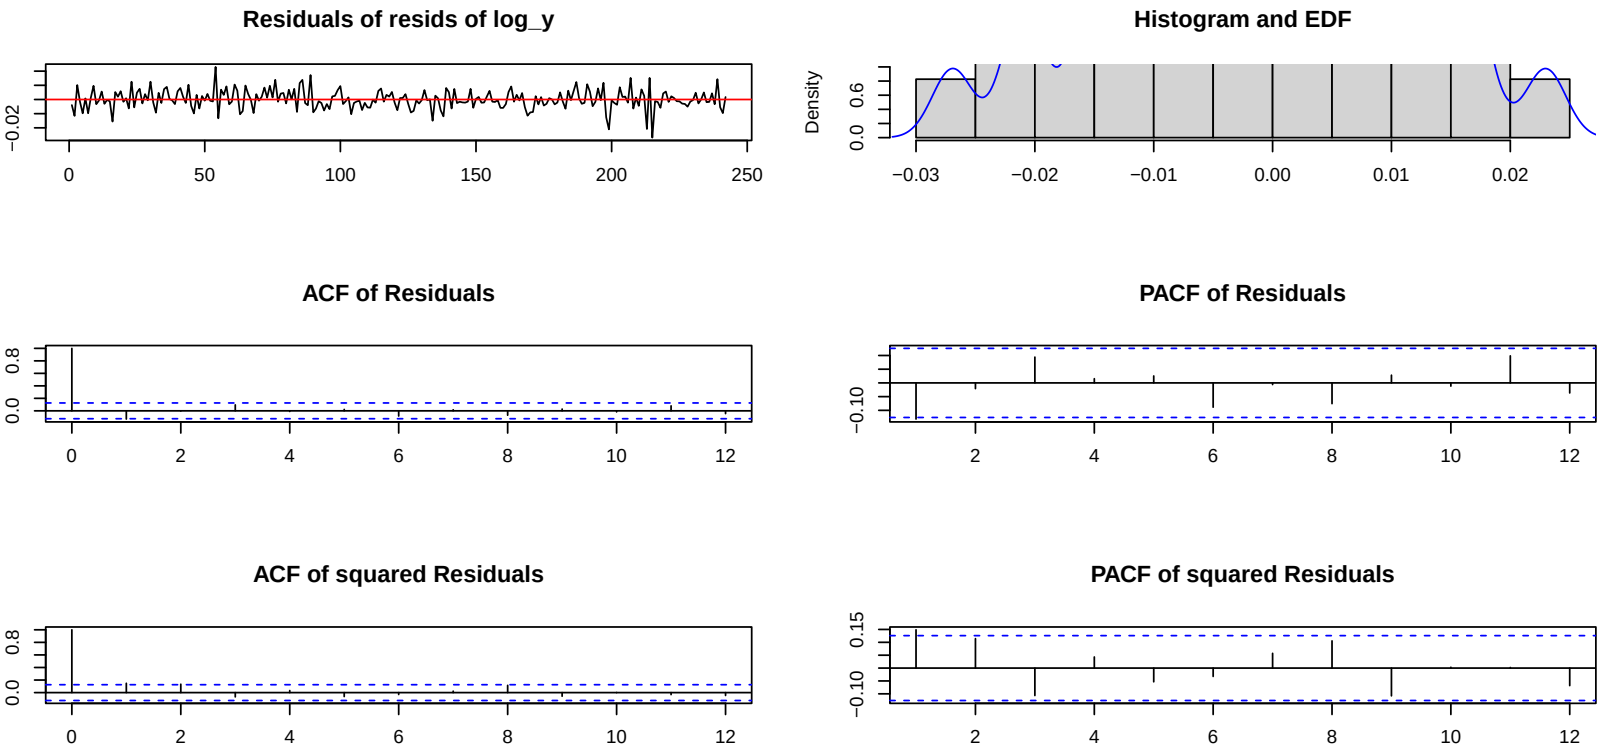

IRF

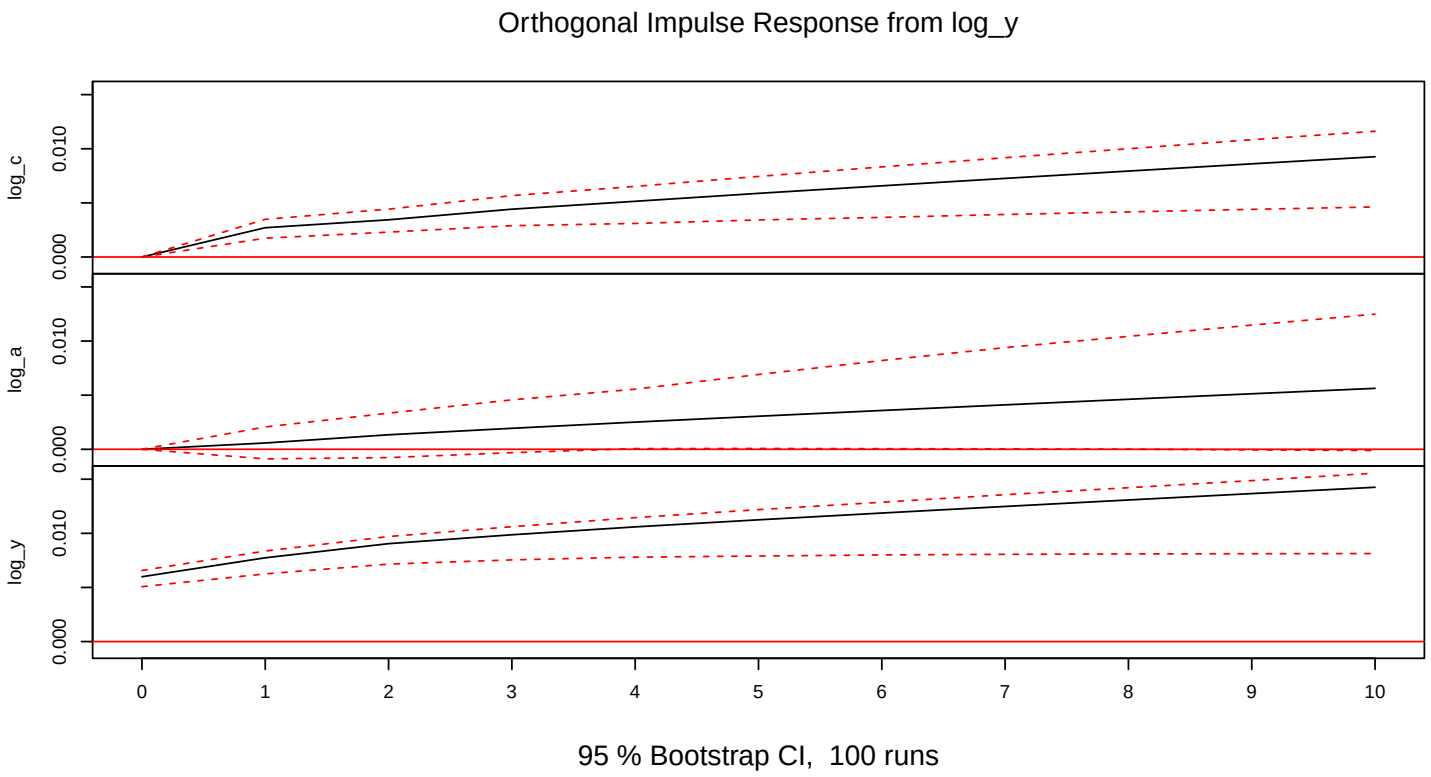
Orthogonal Impulse Response from log_y
log_c
log_a
log_y
0.000
0.010
0
1
2
3
4
5
6
7
8
9
10
95 % Bootstrap CI, 100 runs

Modèle Vectoriel de Correction d'Erreur

- VECM estimé en utilisant les résidus de la régression de cointégration

$$\begin{bmatrix} \Delta c_t \\ \Delta a_t \\ \Delta y_t \end{bmatrix} = \begin{bmatrix} 0.003 \\ (0.000) \\ 0.004 \\ (0.014) \\ 0.003 \\ (0.000) \end{bmatrix} + \begin{bmatrix} -0.000 \\ (0.281) \\ 0.002 \\ (0.037) \\ 0.000 \\ (0.515) \end{bmatrix} \hat{\varepsilon}_{t-1} + \begin{bmatrix} 0.192 & 0.102 & 0.139 \\ 0.005) & (0.000) & (0.004) \\ 0.282 & 0.220 & -0.149 \\ (0.116) & (0.006) & (0.414) \\ 0.369 & 0.061 & -0.139 \\ (0.000) & (0.088) & (0.140) \end{bmatrix} \begin{bmatrix} \Delta c_{t-1} \\ \Delta a_{t-1} \\ \Delta y_{t-1} \end{bmatrix} + \boldsymbol{\eta}_t$$

- Valeurs p entre parenthèses
- Estimation de la relation de cointégration n'a aucun effet sur les erreurs standard
  - Converge rapidement (T)
  - Les paramètres VECM convergent à la racine $\sqrt{T}$

Régression Fallacieuse et Équilibre

- La prudence est nécessaire lorsqu'on travaille avec des données I(1)
  - I(0) sur I(0) : Le cas habituel. Les arguments asymptotiques standards s'appliquent.
  - I(1) sur I(0) : Cette régression est déséquilibrée.
  - I(1) sur I(1) : Cointégration ou régression fallacieuse.
  - I(0) sur I(1) : Cette régression est déséquilibrée.
- La régression fallacieuse peut conduire à de grandes statistiques t lorsque les séries sont indépendantes.
  - Deux processus I(1) non liés, x_t et y_t :

$$x_t = x_{t-1} + \varepsilon_t$$

$$y_t = y_{t-1} + \eta_t$$

  - Lorsque $T = 50$, environ 80% des statistiques t sont significatives
  - Toujours vérifier pour I(1) lors de l'utilisation de données de séries temporelles
  - Si les deux sont I(1), assurez-vous qu'ils sont cointégrés.